

LOCALIZACIÓN DE LESIONES RELACIONADAS CON EL CÁNCER DE PRÓSTATA
SOBRE SECUENCIAS MULTIMODALES BP-MRI

CAMILO EDUARDO GONZÁLEZ GUERRERO

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECAÑICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
PROGRAMA DE PREGRADO EN INGENIERÍA DE SISTEMAS E INFORMÁTICA
BUCARAMANGA
2023



LOCALIZACIÓN DE LESIONES RELACIONADAS CON EL CÁNCER DE PRÓSTATA
SOBRE SECUENCIAS MULTIMODALES BP-MRI

CAMILO EDUARDO GONZÁLEZ GUERRERO

Trabajo de investigación presentado en cumplimiento de los requisitos para el grado de:
Ingeniero de Sistemas e Informática

Director:

Fabio Martínez Carrillo, Ph.D.

Doctor en Ingeniería de Sistemas y Computación

Codirector:

Juan Andrés Olmos Rojas, M.Sc.

Magíster en Matemática Aplicada

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECAÑICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
PROGRAMA DE PREGRADO EN INGENIERÍA DE SISTEMAS E INFORMÁTICA
BUCARAMANGA

2023

AGRADECIMIENTOS

DEDICATORIA

CONTENIDO

	page
INTRODUCCIÓN	11
1. FUNDAMENTOS Y TRABAJO PREVIO	17
1.1. CÁNCER DE PRÓSTATA Y SECUENCIAS BP-MRI	17
1.1.1 Secuencia de imagen ponderada en T2 (T2WI).	19
1.1.2 Secuencia de imagen ponderada en difusión (DWI) y mapas ADC.	21
1.2. ESTRATEGIAS COMPUTACIONALES DE LOCALIZACIÓN	23
1.2.1 Sistemas de ventana deslizante.	23
1.2.2 Sistemas de búsqueda selectiva.	25
1.2.3 Sistemas basados en una única observación.	26
1.3. ANTECEDENTES LOCALIZACIÓN DE LESIONES CS-PCA	29
2. PROBLEMA DE INVESTIGACIÓN	34
3. OBJETIVOS	35
4. MÉTODO PROPUESTO	36
4.1. Conjunto de datos de lesiones de Próstata	36
4.2. Procesamiento de datos	37
4.3. Red de localización de lesiones significativas de cáncer de Próstata	39
4.4. Extracción de características	40
4.5. Predicción de regiones	43
4.6. Contorno de lesiones para la tarea de localización	44
5. DISEÑO EXPERIMENTAL	45

6. EVALUACIÓN Y RESULTADOS 46

7. CONCLUSIONES Y TRABAJO FUTURO 47

BIBLIOGRAFÍA 48

LISTA DE FIGURAS

	page
Figura 1. Ilustración de lesiones en secuencias T2W.	20
Figura 2. Ilustración de lesiones en secuencias DWI.	22
Figura 3. Ilustración de lesiones en secuencias ADC.	23
Figura 4. Estructura del backbone de la red de localización de csPCA	41
Figura 5. Pipeline General para la localización de lesiones csPCA	42

LISTA DE TABLAS

	page
Tabla 1. Comparativa de la utilización de diferentes secuencias	45
Tabla 2. T2W-ADC-DWI-SEG-(150_150) por Thresholds IOUv	45

RESUMEN

TÍTULO: Localización de lesiones relacionadas con el cáncer de próstata sobre secuencias multimodales bp-MRI *

AUTOR: Camilo Eduardo González Guerrero **

PALABRAS CLAVE: Cáncer de próstata, localización, lesión csPCa, bpMRI, multimodal.

DESCRIPCIÓN: El cáncer de próstata es el segundo cáncer con mayor incidencia en hombres a nivel mundial. En Colombia, por ejemplo, la tasa de defunción es de alrededor de 11.6 casos por cada 100 mil habitantes. Hoy en día, el estudio de lesiones prostáticas mediante resonancia magnética biparamétrica es un criterio estándar para la detección y diagnóstico del cáncer de próstata, incluso en estadios tempranos. Sin embargo, la localización de estas lesiones sigue siendo subjetiva y su caracterización reporta bajos niveles de sensibilidad. Es por ello por lo que los mecanismos computacionales son hoy en día claves para la localización, diagnóstico y triage del cáncer de próstata sobre los estudios bp-MRI. En esta propuesta se pretende desarrollar una herramienta de aprendizaje profundo para localizar lesiones prostáticas a partir de la observación de múltiples parámetros de la resonancia. Para lo anterior, se seleccionará un conjunto de datos debidamente anotado por expertos, se ajustará y adaptará una herramienta de aprendizaje profundo. Se espera validar el esquema propuesto en cuanto a la capacidad de localizar lesiones y discriminarlas según la estratificación del conjunto de datos.

* Trabajo de investigación

** Facultad de Ingenierías Fisicomecánicas Escuela de Ingeniería de Sistemas e Informática. Director: Fabio Martínez Carrillo, Ph.D. Codirector: Juan Andrés Olmos Rojas, M.Sc.

ABSTRACT

TITLE: Localization of prostate cancer-related lesions on multimodal bp-MRI sequences. *

AUTHOR: Camilo Eduardo González Guerrero **

KEYWORDS: Prostate cancer, bpMRI, csPCa lesion, multimodal

DESCRIPTION: Prostate cancer is the second cancer with the highest incidence in men worldwide. In Colombia, for example, the death rate is around 11.6 cases per 100,000 inhabitants. Nowadays, the study of prostate lesions through biparametric magnetic resonance imaging is a standard criterion for the detection and diagnosis of prostate cancer, even in early stages. However, the localization of these lesions remains subjective and their characterization reports low levels of sensitivity. This is why computational mechanisms are nowadays key for the localization, diagnosis and triage of prostate cancer on bp-MRI studies. In this proposal we intend to develop a deep learning tool to localize prostate lesions from the assessment of multiple MRI parameters. For the above, a dataset properly annotated by experts will be selected, a deep learning tool will be adjusted and adapted. The proposed schema is expected to be validated in terms of its ability to localize lesions and discriminate them according to the stratification of the dataset.

* Research work

** Faculty of Physics-Mechanics Engineering. School of Systems Engineering and Informatics. Advisor: Fabio Martínez, Ph.D. Co-advisor: Juan Andrés Olmos Rojas, M.Sc.

INTRODUCCIÓN

El cáncer de próstata (PCa) es el segundo cáncer más común en hombres y en la mayoría de los países se establece como el más diagnosticado. En 2020, a nivel global hubo 1.4 millones de casos nuevos y más de 300.000 fallecimientos. Además, se estima que las muertes asociadas a este cáncer se duplicarán para el año 2040 ¹. A nivel mundial, el 6.8% de las muertes por cáncer en hombres son por cáncer de próstata, mientras que en Colombia esta cifra ha presentado un incremento constante en los últimos 20 años, siendo actualmente la causante del 14.5% de las muertes asociadas a cáncer en hombres ¹².

En la práctica clínica, se busca identificar lesiones clínicamente significativas de cáncer de próstata (csPca, por sus siglas en inglés), cuya detección temprana permite reducir el número de lesiones agresivas y la cantidad de muertes asociadas a este cáncer ³. Por ello, un diagnóstico preciso y oportuno es relevante para diseñar mejores tratamientos que impacten positivamente en el paciente. A la fecha, los métodos mas utilizados durante la rutina clínica para el diagnóstico inicial, o sospecha de PCa, son el examen de sangre de antígeno prostático (prostate specific antigen, PSA) y el examen rectal digital (digital rectal

¹ Hyuna SUNG et al. "Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries". In: *CA: A Cancer Journal for Clinicians* 71.3 (Feb. 2021), pp. 209–249. DOI: 10.3322/caac.21660.

² ASÍ VAMOS EN SALUD. *Mortalidad por Cáncer de Próstata*. <https://asivamosensalud.org/indicadores/enfermedades-cronicas-no-transmisibles/tasa-cancer-prostata-georeferenciado>. 2021.

³ Ahmad ABDELRAZEK et al. "Recent Advances in Prostate Cancer (PCa) Diagnostics". In: *Uro* 2.2 (2022), pp. 109–121. DOI: 10.3390/uro2020014.

exam, DRE) ⁴⁵⁶. Sin embargo, se ha mostrado que el examen PSA presenta una baja especificidad, alcanzando cifras cercanas al 20% ⁷. Por otra parte, el DRE es un método invasivo, altamente dependiente de la experiencia del experto y no permite examinar zonas importantes de la glándula prostática, ignorando así potenciales lesiones csPCa ⁸⁹.

El análisis de secuencias de resonancia magnética multi-paramétrica (MP-MRI) se ha constituido en los últimos años como una alternativa prometedora para soportar el diagnóstico temprano en una fase previa a la biopsia ¹⁰. Estas secuencias se usan como una herramienta estándar para el diagnóstico o el tamizaje ('screening') poblacional en diferentes

-
- ⁴ Jurgen J. FÜTTERER et al. "Can Clinically Significant Prostate Cancer Be Detected with Multiparametric Magnetic Resonance Imaging? A Systematic Review of the Literature". In: *European Urology* 68.6 (Dec. 2015), pp. 1045–1053. DOI: 10.1016/j.eururo.2015.01.013.
 - ⁵ Fei WANG et al. "Clinically significant prostate cancer (csPCa) detection with various prostate sampling schemes based on different csPCa definitions". In: *BMC Urology* 21.1 (Dec. 2021). DOI: 10.1186/s12894-021-00949-7.
 - ⁶ Ryan P. SMITH et al. "Identification of Clinically Significant Prostate Cancer by Prostate-Specific Antigen Screening". In: *Archives of Internal Medicine* 164.11 (June 2004), p. 1227. DOI: 10.1001/archinte.164.11.1227.
 - ⁷ Samuel W. D. MERRIEL et al. "Systematic review and meta-analysis of the diagnostic accuracy of prostate-specific antigen (PSA) for the detection of prostate cancer in symptomatic patients". In: *BMC Medicine* 20.1 (Feb. 2022). DOI: 10.1186/s12916-021-02230-y.
 - ⁸ Michael DAVID and Stephen LESLIE. "Prostate specific antigen". In: *StatPearls* (2022).
 - ⁹ Leen NAJI et al. "Digital Rectal Examination for Prostate Cancer Screening in Primary Care: A Systematic Review and Meta-Analysis". In: *The Annals of Family Medicine* 16.2 (Mar. 2018), pp. 149–154. DOI: 10.1370/afm.2205.
 - ¹⁰ Dominik DENIFFEL et al. "Avoiding Unnecessary Biopsy: MRI-based Risk Models versus a PI-RADS and PSA Density Strategy for Clinically Significant Prostate Cancer". In: *Radiology* 300.2 (Aug. 2021), pp. 369–379. DOI: 10.1148/radiol.2021204112.

regiones en el mundo ¹¹¹². En especial, permiten caracterizar lesiones, incluso en regiones alejadas de la pared rectal y zona transicional ¹³¹⁴. Sin embargo, el enfoque MP-MRI implica la utilización de agentes de contraste, que pueden tener efectos secundarios como malestar general o irritación en la piel, debido a la inyección del agente de contraste. Así mismo, requiere un tiempo considerable para generar su secuencia de imágenes, y por si fuera poco, ya se ha relatado sobre una posible no evidencia estadística significativa con el uso de su secuencia (DCE) ¹⁵¹⁶¹⁷¹⁸. De manera que, el uso de secuencias de resonancia magnética bi-paramétricas (bp-MRI) ha emergido como una alternativa, que, en comparación con las secuencias MP-MRI, resultan hasta tres veces más rápidas, no requieren agentes de con-

-
- 11 David ELDRED-EVANS et al. "Population-Based Prostate Cancer Screening With Magnetic Resonance Imaging or Ultrasonography: The IP1-PROSTAGRAM Study". In: *JAMA Oncology* 7.3 (Mar. 2021), pp. 395–402. DOI: 10.1001/jamaoncol.2020.7456. eprint: https://jamanetwork.com/journals/jamaoncology/articlepdf/2776224/jamaoncology_eldredevans_2021_oi_200109_1615397512.10777.pdf.
 - 12 Matthias SAAR et al. "Current Role of Multiparametric MRI and MRI Targeted Biopsies for Prostate Cancer Diagnosis in Germany: A Nationwide Survey". In: *Urologia Internationalis* 104.9-10 (2020), pp. 731–740. DOI: 10.1159/000508755.
 - 13 Gillian MURPHY et al. "The expanding role of MRI in prostate cancer". In: *American Journal of Roentgenology* 201.6 (2013), pp. 1229–1238.
 - 14 Armando STABILE et al. "Multiparametric MRI for prostate cancer diagnosis: current status and future directions". In: *Nature Reviews Urology* 17.1 (July 2019), pp. 41–61. DOI: 10.1038/s41585-019-0212-4.
 - 15 Ashkan Heshmatzadeh BEHZADI et al. "Immediate Allergic Reactions to Gadolinium-based Contrast Agents: A Systematic Review and Meta-Analysis". In: *Radiology* 286.2 (Feb. 2018), pp. 471–482. DOI: 10.1148/radiol.2017162740.
 - 16 M. Teresa Gracia BARA et al. "Hypersensitivity to Gadolinium-Based Contrast Media". In: *Frontiers in Allergy* 3 (Mar. 2022). DOI: 10.3389/falgy.2022.813927.
 - 17 Ivo G. SCHOOTS et al. "PI-RADS Committee Position on MRI Without Contrast Medium in Biopsy-Naive Men With Suspected Prostate Cancer: Narrative Review". In: *American Journal of Roentgenology* 216.1 (Jan. 2021), pp. 3–19. DOI: 10.2214/ajr.20.24268.
 - 18 Cher Heng TAN et al. "Dynamic Contrast-Enhanced MRI for the Detection of Prostate Cancer: Meta-Analysis". In: *American Journal of Roentgenology* 204.4 (Apr. 2015), W439–W448. DOI: 10.2214/ajr.14.13373.

traste y tienen una precisión equiparable en el soporte al diagnóstico ¹⁹²⁰²¹²². A pesar de ello, el análisis de lesiones en secuencias MRI es afectado por la variabilidad que existe entre lecturas por parte de diferentes radiólogos, subjetividad que puede inducir errores en la caracterización y localización de lesiones csPCa. Particularmente, la caracterización de estas lesiones en secuencias bp-MRI es una tarea compleja para los radiólogos, su competencia se logra con experiencia, tanto en años, como en número de interpretaciones ²³²⁴. Sin embargo, no son muchos los radiólogos que cuentan con esta experiencia, y en eventuales diagnósticos masivos, ya existe preocupación por posible escasez de personal ²⁵²⁶. A propósito de lo anterior, se han propuesto ambiciosos programas para fortalecer tareas de tamizaje basados en estudios MRI que permitan mitigar la mortalidad asociada a este

-
- ¹⁹ Martina PECORARO et al. "The future direction of imaging in prostate cancer: MRI with or without contrast injection". In: *Andrology* 9.5 (June 2021), pp. 1429–1443. DOI: 10.1111/andr.13041.
 - ²⁰ Verena C. OBMANN et al. "Diagnostic Accuracy of a Rapid Biparametric MRI Protocol for Detection of Histologically Proven Prostate Cancer". In: *Urology* 122 (Dec. 2018), pp. 133–138. DOI: 10.1016/j.urology.2018.08.032.
 - ²¹ Kadir Han ALVER et al. "Comparison of Multiparametric and Fast scpMRI/scp Protocols in Detecting Clinically Significant Prostate Cancer and a Detailed Cost Analysis". In: *Journal of Magnetic Resonance Imaging* 56.5 (Mar. 2022), pp. 1437–1447. DOI: 10.1002/jmri.28142.
 - ²² Fabian STEINKOHL; Renate PICHLER, and Daniel JUNKER. "Short review of biparametric prostate MRI". in: *memo - Magazine of European Medical Oncology* 11.4 (Nov. 2018), pp. 309–312. DOI: 10.1007/s12254-018-0458-1.
 - ²³ Bassel R. SALKA et al. "Effect of Prostate MRI Interpretation Experience on PPV Using PI-RADS Version 2: A 6-Year Assessment Among Eight Fellowship-Trained Radiologists". In: *American Journal of Roentgenology* 219.3 (Sept. 2022), pp. 453–460. DOI: 10.2214/ajr.22.27421.
 - ²⁴ Hyunseon C. KANG et al. "Accuracy of Prostate Magnetic Resonance Imaging: Reader Experience Matters". In: *European Urology Open Science* 27 (May 2021), pp. 53–60. DOI: 10.1016/j.euros.2021.03.004.
 - ²⁵ Lidia Alcalá MATA et al. "Artificial Intelligence–assisted Prostate Cancer Diagnosis: Radiologic-Pathologic Correlation". In: *RadioGraphics* 41.6 (Oct. 2021), pp. 1676–1697. DOI: 10.1148/rg.2021210020.
 - ²⁶ Abi RIMMER. "Radiologist shortage leaves patient care at risk, warns royal college". In: *BMJ* (Oct. 2017), j4683. DOI: 10.1136/bmj.j4683.

cáncer ²⁷. Ahora bien, en relación a resultados coetáneos, de programas de tamizaje previo, se evidencia que las labores de clasificación, o determinación de un grado en una escala para este tipo de cáncer no han sido muy efectivas, pues no hay evidencia de disminución en la mortalidad ²⁸. Anejando por lo dicho, para una correcta caracterización, resultarían necesarias herramientas que especialicen la tarea de localización de lesiones sobre estas secuencias MRI.

En los últimos años, el uso de herramientas computacionales ha surgido como una herramienta prometedora para ayudar en el diagnóstico y localización de esta enfermedad ²⁹³⁰. Entre estos métodos, sobresalen los modelos de aprendizaje profundo, los cuales permiten clasificar lesiones clínicamente significativas con una precisión sobresaliente e incluso comparable con la de expertos lectores radiólogos ²⁵. A pesar de ello, el diseño de estas estrategias supone un conjunto de datos que incluya una localización precisa de las lesiones para ajustar los modelos ³¹. Algunos trabajos relacionados comprenden, la determinación de la agresividad de lesiones csPCA en resonancias, a partir de correlación con imágenes

²⁷ Ola BRATT et al. "Screening for prostate cancer: evidence, ongoing trials, policies and knowledge gaps". In: *BMJ Oncology* 2.1 (Apr. 2023), e000039. DOI: 10.1136/bmjonc-2023-000039.

²⁸ Freddie C. HAMDY; Jenny L. DONOVAN, and J. Athene Lane et AL. "Fifteen-Year Outcomes after Monitoring, Surgery, or Radiotherapy for Prostate Cancer". In: *New England Journal of Medicine* 388.17 (Apr. 2023), pp. 1547–1558. DOI: 10.1056/nejmoa2214122.

²⁹ Milap SHAH et al. "Current Applications of Artificial Intelligence in Benign Prostatic Hyperplasia". In: *Türk Üroloji Dergisi/Turkish Journal of Urology* 48.4 (July 2022), pp. 262–267. DOI: 10.5152/tud.2022.22028.

³⁰ Olivier ROUVIÈRE et al. "Artificial intelligence algorithms aimed at characterizing or detecting prostate cancer on MRI: How accurate are they when tested on independent cohorts? – A systematic review". In: *Diagnostic and Interventional Imaging* 104.5 (May 2023), pp. 221–234. DOI: 10.1016/j.diii.2022.11.005.

³¹ Jose M. Castillo T. et al. "Classification of Clinically Significant Prostate Cancer on Multi-Parametric MRI: A Validation Study Comparing Deep Learning and Radiomics". In: *Cancers* 14.1 (Dec. 2021), p. 12. DOI: 10.3390/cancers14010012.

histopatológicas ³², predicción de lesiones csPCA utilizando estrategias de tranfer learning ³³, predicción del grado histopátológico de Gleason sobre secuencias MRI, a partir del uso de clasificadores KNN ³⁴, o la detección y clasificación a través de redes U-NET en cascada ³⁵. Así pues, la mayoría de estrategias intentan resolver la detección y/o clasificación de lesiones csPCA, más no dilucidan el potencial de poder especializarse en la localización de lesiones potencialmente mortales. Por lo tanto, resulta relevante el diseño de herramientas de aprendizaje automático que resulten precisas y eficaces en tareas de localización de lesiones csPCA.

Este trabajo propone la implementación de una herramienta de aprendizaje profundo para la localización de lesiones csPCA en estudios bp-MRI que sirva de apoyo a labores radiológicas y urológicas de ('screening'). Para ello, se seleccionará un conjunto de datos que contenga imágenes bp-MRI, junto con anotaciones relacionadas con la localización y grado de malignidad de las lesiones. Estos datos serán utilizados para desarrollar y entrenar un algoritmo de aprendizaje profundo con la capacidad de localizar lesiones csPCA. Además, se evaluará la efectividad del algoritmo en comparación con los métodos tradicionales y se discutirán las implicaciones clínicas de su uso.

³² Arun SEETHARAMAN et al. "Automated detection of aggressive and indolent prostate cancer on magnetic resonance imaging". In: *Medical Physics* 48.6 (May 2021), pp. 2960–2972. DOI: 10.1002/mp.14855.

³³ Quan CHEN et al. "A Transfer Learning Approach for Malignant Prostate Lesion Detection on Multiparametric MRI". in: *Technology in Cancer Research & Treatment* 18 (Jan. 2019), p. 153303381985836. DOI: 10.1177/1533033819858363.

³⁴ Carina JENSEN et al. "Assessment of prostate cancer prognostic Gleason grade group using zonal-specific features extracted from biparametric MRI using a KNN classifier". In: *Journal of Applied Clinical Medical Physics* 20.2 (Feb. 2019), pp. 146–153. DOI: 10.1002/acm2.12542.

³⁵ Sherif MEHRALIVAND; Dong YANG, and Stephanie A. Harmon et AL. "A Cascaded Deep Learning–Based Artificial Intelligence Algorithm for Automated Lesion Detection and Classification on Biparametric Prostate Magnetic Resonance Imaging". In: *Academic Radiology* 29.8 (Aug. 2022), pp. 1159–1168. DOI: 10.1016/j.acra.2021.08.019.

1. FUNDAMENTOS Y TRABAJO PREVIO

En este capítulo se presenta una descripción general del contexto del cáncer de próstata (Sección 1.1), sus implicaciones, estándares de diagnóstico, imagenología utilizada y sus parámetros. Seguidamente, en la Sección (1.2) se relatarán los métodos o estrategias computacionales que han sido desarrolladas para tareas generales de detección y localización. En la Sección (1.3) se presentan algunos de los enfoques computacionales y de aprendizaje automático que han abordado la identificación de lesiones prostáticas o la estimación de su agresividad.

1.1. CÁNCER DE PRÓSTATA Y SECUENCIAS BP-MRI

El cáncer de próstata se desarrolla como un tumor maligno, originado en la glándula prostática³⁶. Este cáncer tiene implicación directa en el desarrollo reproductivo masculino, así como el bienestar, calidad de vida y salud mental de los pacientes³⁷³⁸³⁹. Actualmente las técnicas más utilizadas para el diagnóstico y la evaluación del cáncer de próstata se basan en pruebas como el antígeno prostático específico (PSA), el tacto rectal (DRE), la biopsia de próstata y la resonancia magnética multiparamétrica (mp-MRI)⁴⁰.

³⁶ “Prostate cancer”. In: *Nursing Standard* 30.40 (June 2016), pp. 17–17. DOI: 10.7748/ns.30.40.17.s20.

³⁷ Lee Anne WALMSLEY. *The psychological well-being of men diagnosed with prostate cancer*. University of Kentucky, 2015.

³⁸ AnnMarie GROARKE et al. “Quality of life and adjustment in men with prostate cancer: Interplay of stress, threat and resilience”. In: *PLOS ONE* 15.9 (Sept. 2020). Ed. by Ali MONTAZERI, e0239469. DOI: 10.1371/journal.pone.0239469.

³⁹ Rodolfo Alberto REY et al. “Male hypogonadism: an extended classification based on a developmental, endocrine physiology-based approach”. In: *Andrology* 1.1 (2013), pp. 3–16.

⁴⁰ Richard J. REBELLO et al. “Prostate cancer”. In: *Nature Reviews Disease Primers* 7.1 (Feb. 2021). DOI: 10.1038/s41572-020-00243-0.

La mp-MRI es una técnica de imagen diagnóstica que permite evaluar la próstata de manera funcional y morfológica, demostrando ser útil para los radiólogos en la detección y localización de tumores. Además, ha sido recomendada ampliamente como la herramienta directa para el diagnóstico inicial ^{41,42}. Los estudios mp-MRI se componen de tres secuencias diferentes: *T2-weighted imaging* (T2WI), *diffusion-weighted imaging* (DWI) y *dynamic contrast-enhanced* (DCE) imaging, a partir de las cuales se puede obtener información detallada sobre la anatomía, metabolismo y vascularización de la próstata. Para la interpretación e informe de los hallazgos en mp-MRI de próstata se utiliza el sistema PI-RADS 2.1 (Prostate Imaging Reporting and Data System) ⁴². Este esquema imagenológico, establece criterios para el procesamiento de datos y la generación de reportes, asignando una puntuación según la probabilidad de que una lesión observada en mp-MRI corresponda a una lesión csPCA baja (categoría 1 o 2 de PI-RADS), intermedia (categoría 3 de PI-RADS) o alta (categoría 4 o 5 de PI-RADS). El sistema PI-RADS se basa en la valoración de parámetros como la anatomía zonal de la próstata, la difusión del agua, la perfusión sanguínea, entre otros ⁴³.

Por su parte, la imagenología bp-MRI es una técnica de resonancia magnética de análisis imagenológico, basada únicamente en el reconocimiento de patrones de lesión en secuencias T2WI, DWI y mapas ADC, descartando las imágenes de contraste DCE ⁴⁴. Esta config-

⁴¹ Maria Clara FERNANDES et al. "The role of MRI in prostate cancer: current and future directions". In: *Magnetic Resonance Materials in Physics, Biology and Medicine* 35.4 (Mar. 2022), pp. 503–521. DOI: 10.1007/s10334-022-01006-6.

⁴² Tristan BARRETT et al. "Quality checkpoints in the MRI-directed prostate cancer diagnostic pathway". In: *Nature Reviews Urology* 20.1 (Sept. 2022), pp. 9–22. DOI: 10.1038/s41585-022-00648-4.

⁴³ Thomas BEYER et al. "PI-RADS 2.1 – Image Interpretation: The Most Important Updates and Their Clinical Implications". In: *RöFo - Fortschritte auf dem Gebiet der Röntgenstrahlen und der bildgebenden Verfahren* (Dec. 2020). DOI: 10.1055/a-1324-4010.

⁴⁴ Michele SCIALPI et al. "Biparametric MRI of the prostate". In: *Türk Üroloji Dergisi/Turkish Journal of Urology* 43.4 (Nov. 2017), pp. 401–409. DOI: 10.5152/tud.2017.06978.

uración logra simplificar el protocolo de MRI, reduciendo el tiempo, el costo, y, a diferencia de la mp-MRI, no se expone al paciente a agentes de contraste ⁴⁵. Por otra parte, estudios preliminares han mostrado que el desempeño de la mp-MRI y la bp-MRI para efectos de interpretación radiológica, es indistinto ⁴⁶. Por lo anterior, la bp-MRI se considera actualmente como una modalidad de imagenología que ofrece una alternativa válida y eficiente para el diagnóstico del csPCA. A continuación se detallan las secuencias que componen los estudios bp-MRI.

1.1.1. Secuencia de imagen ponderada en T2 (T2WI). El parámetro T2WI de la resonancia magnética permite, principalmente, obtener una representación anatómica. Esta técnica se fundamenta en la vibración de las moléculas de agua y su tiempo de relajación. En el caso de la próstata, la T2WI permite visualizar la anatomía zonal de la glándula y detectar lesiones en diferentes planos (transaxial, coronal y sagital) ¹³. La intensidad de la señal en la T2WI puede variar según la ubicación y las características de las lesiones, lo que puede llevar a confusiones con otras enfermedades como la prostatitis, la hiperplasia prostática benigna (HPB) y las hemorragias post-biopsia ⁴⁷. En la Figura 1 se ilustran cortes de esta secuencia para diferentes pacientes, en el panel izquierdo: en la parte superior se presentan tres casos con lesión csPCa (Pacientes A, B, y C) y en la parte inferior tres casos diferentes (Pacientes D,E, y F) con glándulas prostáticas sin lesión. En el panel derecho: se muestra una representación volumétrica de la glándula, vista superior, lateral y de perfil del volumen de una glándula de referencia. En verde, azul y rojo se presenta la localización de

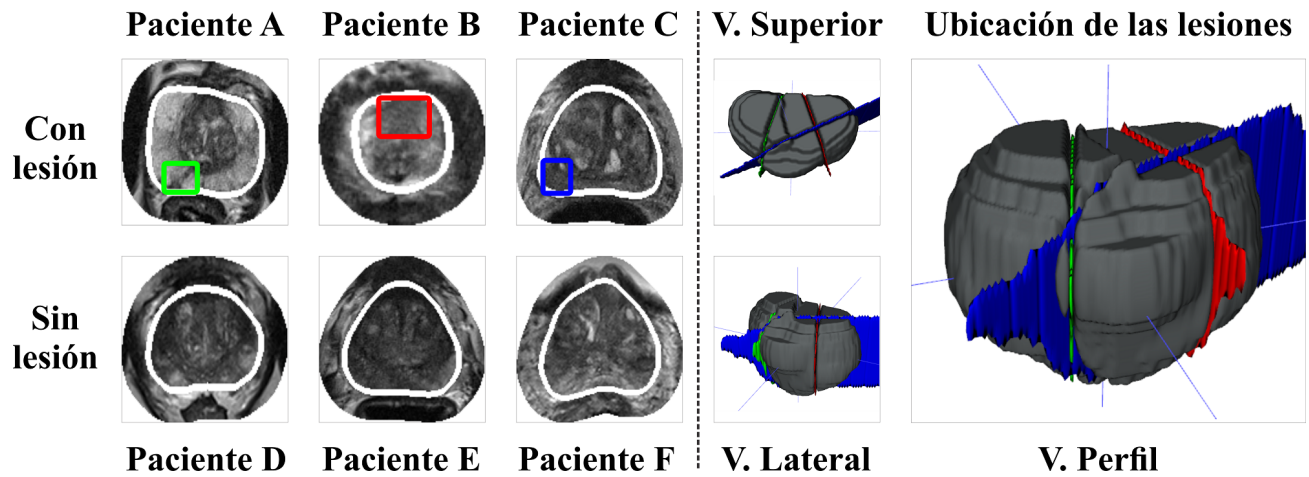
⁴⁵ Helen XU et al. "Prostate cancer detection using residual networks". In: *International Journal of Computer Assisted Radiology and Surgery* 14.10 (Apr. 2019), pp. 1647–1650. DOI: 10.1007/s11548-019-01967-5.

⁴⁶ M. DE ROOIJ. "Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: preliminary results from the PI-CAI Challenge". In: *Preliminary results from the PI-CAI Challenge*. EAU 2023. Milan, Italia.: EAU 2023 Prostate Cancer, 2023.

⁴⁷ James THOMPSON et al. "The role of magnetic resonance imaging in the diagnosis and management of prostate cancer". In: *BJU international* 112 (2013), pp. 6–20.

los cortes correspondientes a las lesiones de los pacientes A, B, y C.

Figura 1. Ilustración de lesiones en secuencias T2W.



Nota: Figura construida con el uso de datos bp-MRI de próstata de centros médicos de los Países Bajos ⁴⁸, y procesadas con el software ITK-SNAP ⁴⁹.

1.1.2. Secuencia de imagen ponderada en difusión (DWI) y mapas ADC. La secuencia DWI constituye un tipo de imagen que se fundamenta en la movilidad espontánea de las moléculas de agua, conocida como movimiento Browniano ⁵⁰. Esta secuencia resulta valiosa para obtener información acerca del entorno y los tejidos, debido a que está estrechamente relacionada con las interacciones funcionales del espacio intra y extracelular ⁵¹⁵². Característico de esta, es el valor b (b-value), configurable en la adquisición de la secuencia, y connota tiempos y fuerzas de los gradientes que se aplicarán para obtenerla. Convencionalmente, se obtienen secuencias DWI, con diferentes b-value, y es a partir de ellas que se puede llevar a cabo una cuantificación para detectar posibles anomalías en los tejidos mediante los mapas de Coeficiente de Difusión Aparente (ADC) ⁵³. Un ADC bajo, que denota un flujo exiguo de agua o difusión reducida, estaría relacionado con tumores o progresiones cancerígenas, que en su mayoría emergen de la producción de biomasa, generando un aumento en la densidad celular y limitando el espacio inter y extracelular disponible. Por el contrario, un flujo desproporcionado podría indicar una degradación celu-

⁵⁰ Martin H MAURER and Johannes T HEVERHAGEN. “Diffusion weighted imaging of the prostate—principles, application, and advances”. In: *Translational andrology and urology* 6.3 (2017), p. 490.

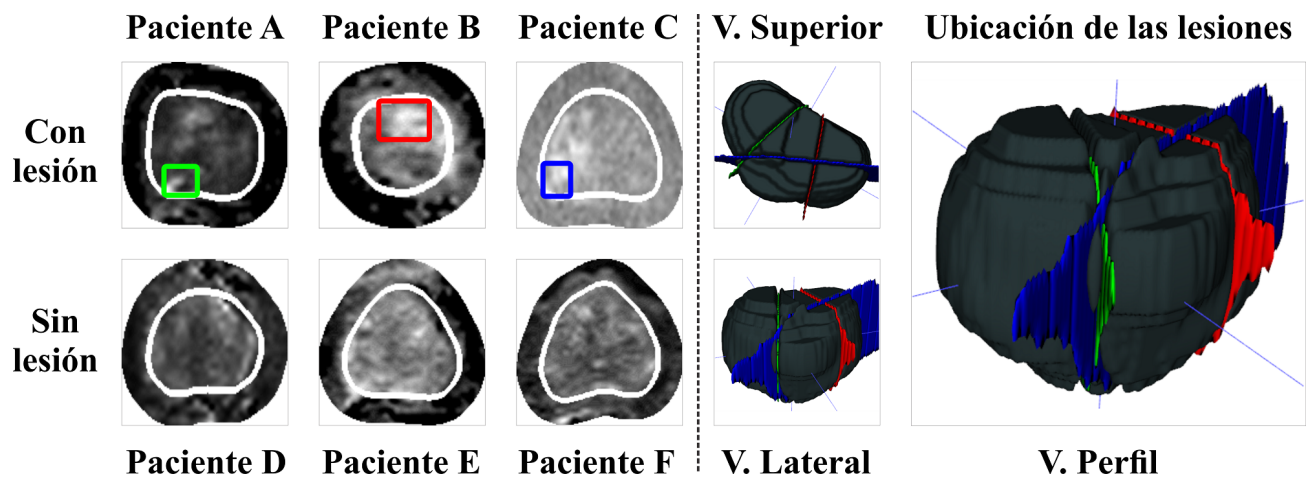
⁵¹ Dow-Mu KOH and David J. COLLINS. “Diffusion-Weighted MRI in the Body: Applications and Challenges in Oncology”. In: *American Journal of Roentgenology* 188.6 (June 2007), pp. 1622–1635. DOI: 10.2214/ajr.06.1403.

⁵² Iztok CAGLIC and Tristan BARRETT. “Diffusion-weighted imaging (DWI) in lymph node staging for prostate cancer”. In: *Translational Andrology and Urology* 7.5 (Oct. 2018), pp. 814–823. DOI: 10.21037/tau.2018.08.04.

⁵³ Amol Madanlal LAHOTI et al. “Role and application of diffusion-weighted imaging in evaluation of prostate cancer”. In: *Indian Journal of Medical and Paediatric Oncology* 39.03 (2018), pp. 349–354.

lar severa o tejido necrótico ⁵⁴⁵⁰⁵⁵. En la Figura 2 y Figura 3 se ilustran cortes de estas secuencias, para diferentes pacientes, además se ilustran casos de glándulas prostáticas con y sin lesión relacionada con el cáncer de próstata. En el panel derecho se muestra una representación volumétrica de la glándula y de los cortes donde se encuentran localizadas las lesiones.

Figura 2. Ilustración de lesiones en secuencias DWI.

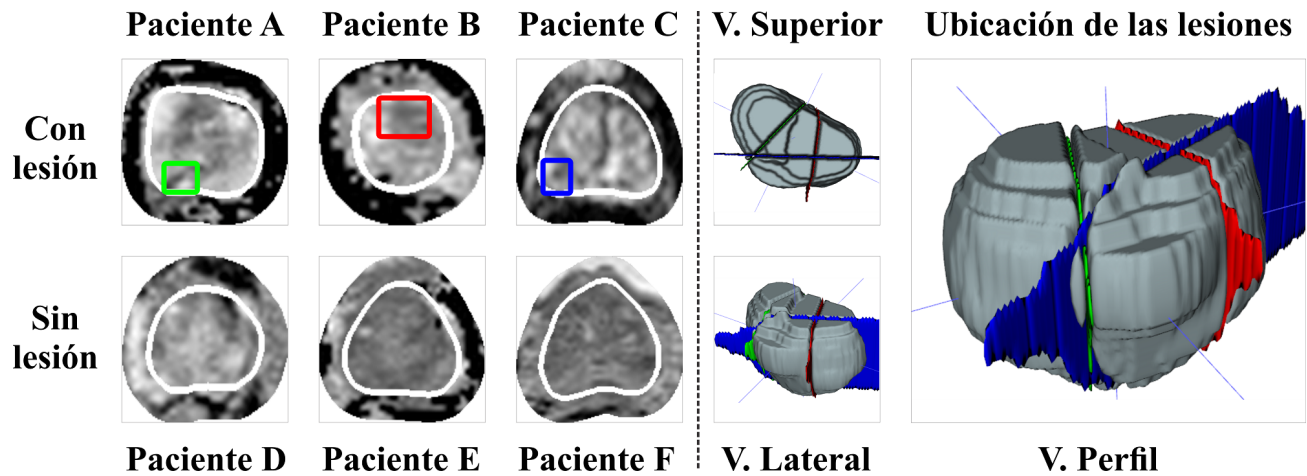


Nota: Figura construida con el uso de datos bp-MRI de próstata de centros médicos de los Países Bajos ⁵⁶, y procesadas con el software ITK-SNAP ⁵⁷.

⁵⁴ Tom J. SYER et al. "The diagnostic accuracy of high b-value diffusion- and T2-weighted imaging for the detection of prostate cancer: a meta-analysis". In: *Abdominal Radiology* 43.7 (Nov. 2017), pp. 1787–1797. DOI: 10.1007/s00261-017-1400-4.

⁵⁵ Michael A JACOBS et al. "Diffusion weighted imaging with ADC mapping and spectroscopy in prostate cancer". In: *Topics in magnetic resonance imaging: TMRI* 19.6 (2008), p. 261.

Figura 3. Ilustración de lesiones en secuencias ADC.



Nota: Figura construida con el uso de datos bp-MRI de próstata de centros médicos de los Países Bajos ⁵⁸, y procesadas con el software ITK-SNAP ⁵⁹.

1.2. ESTRATEGIAS COMPUTACIONALES DE LOCALIZACIÓN

En esta sección se realiza un breve compendio sobre herramientas que se han propuesto para la tarea de localización. Para esto, se pueden identificar tres categorías principales en las que se agrupan estos métodos: sistemas de ventana deslizante, sistemas de búsqueda selectiva y sistemas basados en una única observación.

1.2.1. Sistemas de ventana deslizante. Los sistemas de ventana deslizante son técnicas que fueron ampliamente utilizadas para el procesamiento de imágenes y la detección de objetos de interés. Estos sistemas se basan en la aplicación de un escaneo a diferentes regiones de la imagen, obtenidas mediante el desplazamiento de una ventana o cuadrícula de tamaño fijo a lo largo de la misma. Para mejorar el rendimiento en detección, se ha propuesto extraer características relevantes de las regiones de la ventana, por ejemplo, a través de una muestra local que estime información relevante, y a su vez, escanee cambios en la

imagen ⁶⁰. Algunos ejemplos de sistemas de ventana deslizante son los basados en las características de Haar wavelet (Haar), Scale-Invariant Feature Transform (SIFT) o Histogram of Oriented Gradients (HOG).

Los sistemas basados en Haar propenden por hallar diferencias basadas en la variación de intensidad entre regiones adyacentes de la imagen, con la finalidad de establecer representaciones estructurales, que serán posteriormente procesados por clasificadores como máquinas de soporte vectorial (SVM, por sus siglas en inglés) ⁶¹. En la literatura, este método es combinado con un algoritmo de aprendizaje llamado AdaBoost para mejorar la capacidad de discriminación entre objetos y fondos. Esta estrategia es conocida por su eficiencia y mejora en la precisión, por ejemplo, para tareas de detección de objetos ⁶². Por otra parte, el sistema SIFT busca extraer características que sean distintivas e invariantes de las imágenes, aún cuando le son aplicadas transformaciones o quizás distorsiones, como escalamientos, rotaciones, ruido, iluminación y demás cambios de apariencia, esto mediante la asignación de un descriptor basado en el gradiente local. El método es ampliamente utilizado para el reconocimiento de objetos y ha demostrado ser efectivo incluso en escenarios con problemas de oclusión, logrando además, un rendimiento casi de tiempo real ⁶³. Finalmente, los sistemas basados en HOG utilizan distribuciones probabilísticas de los gradientes locales en diferentes regiones de la imagen para de esta forma capturar de mejor manera características invariantes. Posteriormente, estas distribuciones alcanzadas son uti-

⁶⁰ G. DE CROON. "Active object detection". In: vol. IU. MTSV/-. 2007, 97 – 103.

⁶¹ Constantine PAPAGEORGIOU and Tomaso POGGIO. In: *International Journal of Computer Vision* 38.1 (2000), pp. 15–33. DOI: 10.1023/a:1008162616689.

⁶² P. VIOLA and M. JONES. "Rapid object detection using a boosted cascade of simple features". In: *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001*. Vol. 1. 2001, pp. I–I. DOI: 10.1109/CVPR.2001.990517.

⁶³ David G. LOWE. "Distinctive Image Features from Scale-Invariant Keypoints". In: *International Journal of Computer Vision* 60.2 (Nov. 2004), pp. 91–110. DOI: 10.1023/b:visi.0000029664.99615.94.

lizadas para entrenar un clasificador lineal como SVM.⁶⁴ Algunas de estas metodologías han sido utilizadas para recalar en la localización y detección de lesiones prostáticas en MRI⁶⁵⁶⁶.

1.2.2. Sistemas de búsqueda selectiva. Con el antecedente de las redes convolucionales (CNN), los sistemas de búsqueda selectiva afloran como una propuesta para generar conjuntos de regiones candidatas, que puedan contener objetos, para una ulterior clasificación. Por ejemplo, el algoritmo *Regions with CNN features* (R-CNN) para la detección de objetos, combina la postulacion de regiones con las características extraídas por una red neuronal convolucional (CNN). Propiamente, este algoritmo genera propuestas de regiones por imagen, luego extrae un vector de características que se proyecta a un clasificador⁶⁷. La R-CNN cuenta con diferentes actualizaciones y mejoras entre las que se enmarca la Fast R-CNN, la Faster R-CNN y la Mask R-CNN⁶⁸.

La primera, Fast R-CNN, postula una red que se encarga del proceso de proponer regiones, haciéndolo de manera más eficiente. Esta red también se reconoce por la introducción del concepto Region of Interest (RoI) Pooling, empleado para proyectar las regiones candi-

⁶⁴ N. DALAL and B. TRIGGS. "Histograms of Oriented Gradients for Human Detection". In: *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*. IEEE. DOI: 10.1109/cvpr.2005.177.

⁶⁵ Chunjun QIAN et al. "In vivo MRI based prostate cancer localization with random forests and auto-context model". In: *Computerized Medical Imaging and Graphics* 52 (Sept. 2016), pp. 44–57. DOI: 10.1016/j.compmedimag.2016.02.001.

⁶⁶ Nathan LAY et al. "Detection of prostate cancer in multiparametric MRI using random forest with instance weighting". In: *Journal of Medical Imaging* 4.2 (June 2017), p. 024506. DOI: 10.1117/1.jmi.4.2.024506.

⁶⁷ Ross GIRSHICK et al. "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation". In: *2014 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE, June 2014. DOI: 10.1109/cvpr.2014.81.

⁶⁸ O. HMIDANI and E. M. ISMAILI ALAOU. "A comprehensive survey of the R-CNN family for object detection". In: *2022 5th International Conference on Advanced Communication Technologies and Networking (CommNet)*. 2022, pp. 1–6. DOI: 10.1109/CommNet56067.2022.9993862.

datos sobre los mapas de características de la CNN ⁶⁹. En consideración, la Faster R-CNN basa su detección en la Fast R-CNN, agregando una red de propuestas de regiones (RPN, region proposal network), que dispensa del algoritmo de búsqueda selectiva. Además, realiza la tarea directamente desde el mapa de características de la CNN, acelera el proceso de detección, se destaca que comparten características convolucionales con la red de detección ⁷⁰. Por otra parte, fue introducida la Mask R-CNN, que adiciona un proceso de segmentación semántica, donde se añade una rama paralela que genera una máscara binaria para cada región candidata. De esta forma, Mask R-CNN puede producir no solo la clase y la caja delimitadora del objeto, sino también una delineación del contorno del objeto ⁷¹. Estas arquitecturas en relación al cáncer de próstata han sido integradas en etapas de preprocesamiento ⁷²⁷³⁷⁴.

1.2.3. Sistemas basados en una única observación. Los sistemas de detección de objetos en imágenes basados en una única observación son una aplicación innovadora que abrió nuevas perspectivas en el campo de visión por computador. Algunos de los sistemas

⁶⁹ Ross GIRSHICK. *Fast R-CNN*. 2015. DOI: 10.48550/ARXIV.1504.08083.

⁷⁰ Shaoqing REN et al. *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. 2015. DOI: 10.48550/ARXIV.1506.01497.

⁷¹ Kaiming HE et al. *Mask R-CNN*. 2017. DOI: 10.48550/ARXIV.1703.06870.

⁷² Mukesh SONI et al. "Light Weighted Healthcare CNN Model to Detect Prostate Cancer on Multiparametric MRI". in: *Computational Intelligence and Neuroscience 2022* (May 2022). Ed. by Vijay KUMAR, pp. 1–11. DOI: 10.1155/2022/5497120.

⁷³ Z. DAI et al. "Accurate Prostate Cancer Detection and Segmentation Using Non-Local Mask R-CNN With Histopathological Ground Truth". In: *International Journal of Radiation Oncology*Biophysics* 111.3 (Nov. 2021), S45. DOI: 10.1016/j.ijrobp.2021.07.123.

⁷⁴ Zhiyu LIU et al. "A Two-Stage Approach for Automated Prostate Lesion Detection and Classification with Mask R-CNN and Weakly Supervised Deep Neural Network". In: *Artificial Intelligence in Radiation Therapy*. Springer International Publishing, 2019, pp. 43–51. DOI: 10.1007/978-3-030-32486-5_6.

que operan bajo este concepto incluyen You Only Look Once (YOLO) ⁷⁵, Single Shot Multi-Box Detector (SSD) ⁷⁶, RetinaNet ⁷⁷, SpineNet ⁷⁸ y DEtection TRansformer (DETR) ⁷⁹.

A diferencia de los algoritmos de sistema de búsqueda selectiva, estos algoritmos realizan la detección de objetos en una sola pasada a través de la red neuronal y utilizan diferentes estrategias para mejorar la precisión y el equilibrio entre las clases de objetos. Por ejemplo, la estrategia YOLO es una técnica de detección de objetos en tiempo real que propone dividir la imagen en una cuadrícula de celdas, sobre las cuales se ejecutarán tareas de detección. Para esto, en cada celda son propuestos unos cuadro delimitadores, a los cuales, durante el entrenamiento se les asigna puntuaciones, en referencia a la confianza y precisión por la existencia de un objeto de cierta clase en dicho cuadro delimitador. La red ajusta también la ubicación y el tamaño de los cuadros delimitadores, maximizando su precisión de forma que se seleccione el cuadro más confiable. Específicamente, la red YOLO involucra una función de pérdida que tiene en cuenta varios factores: la precisión de la localización del cuadro delimitador, la confianza de la detección y la precisión de la clasificación de objetos. Su uso se ha extendido a tareas como la vigilancia, la conducción autónoma, incluso el reconocimiento de imágenes ⁷⁵. Por su parte, Single Shot MultiBox Detector (SSD) es una propuesta para detección en tiempo real, que a diferencia de la YOLO, busca simplificar y ser mas eficiente en el proceso de selección de los cuadros delimitadores. Esto lo logra me-

⁷⁵ Joseph REDMON et al. *You Only Look Once: Unified, Real-Time Object Detection*. 2015. DOI: 10.48550/ARXIV.1506.02640.

⁷⁶ Wei LIU et al. "SSD: Single Shot MultiBox Detector". In: *Computer Vision – ECCV 2016*. Springer International Publishing, 2016, pp. 21–37. DOI: 10.1007/978-3-319-46448-0_2.

⁷⁷ Tsung-Yi LIN et al. *Focal Loss for Dense Object Detection*. 2017. DOI: 10.48550/ARXIV.1708.02002.

⁷⁸ Xianzhi DU et al. *SpineNet: Learning Scale-Permuted Backbone for Recognition and Localization*. 2019. DOI: 10.48550/ARXIV.1912.05027.

⁷⁹ Nicolas CARION et al. *End-to-End Object Detection with Transformers*. 2020. DOI: 10.48550/ARXIV.2005.12872.

diante un enfoque multi-escala, el cual mejora la detección de objetos de diferentes tamaños al hacer el análisis de cajas delimitadoras sobre características de diferente resolución. De manera similar a la YOLO, la red genera puntuaciones para la presencia de cada categoría de objeto en cada caja delimitadora. Además, se combinan las predicciones de los múltiples mapas de características, incluyendo así una detección mas robusta que trate con diferentes tamaños de objeto ⁷⁶. Sin embargo, esta robustez de las características alcanzadas en esta red, dependen de los cuadro delimitadores definidos desde un inicio. A partir de esto, surge RetinaNet, una red para detección de objetos que se compone de una CNN de tipo ResNet, y cuya principal contribución se centra en la introducción de una Feature Pyramid Network (FPN). FPN toma características profundas y crea una piramide de características a diferente grado de resolución. Seguidamente, se utilizan dos subredes: una de clasificación para los niveles de la FPN, regida por una pérdida focal que soporta el problema de desbalance de clases en imágenes con mucho fondo, esto asignando un mayor peso a las cajas delimitadoras que contienen objetos difíciles de detectar o poco frecuentes; y una segunda red dedicada a la predicción a través de regresión, de los centros y áreas de las cajas delimitadoras. Los experimentos muestran que la RetinaNet, con la pérdida focal propuesta, supera a los detectores que la anteceden ⁷⁷. En vía de crear una mejor fusión de características multi-escala, el equipo de Google propuso la SpineNet. Esta propuesta identifica como un problema para la tarea de localización y detección, la captura de características a través de una reducción espacial, como lo hace el método involucrado en la FPN. Por el contrario, introducen un método más eficaz con un backbone dinámico, donde los mapas de características se proyectan a través de conexiones entre diferentes escalas. Para esto, la SpineNet utiliza técnicas de diseño automático de arquitectura (NAS, por sus siglas en ingles *Neural Architecture Search*). Como resultado, demuestran que esta estrategia permite capturar mejor la información espacial y fusionar mejor la información, dos aspectos claves en tareas de detección ⁷⁸. Por último, se han propuesto recientemente redes que involucran mecanismos de atención mediante la introducción de arquitecturas *Transformer* en el

codificador extractor de características y generador de los cuadros candidatos. Este tipo de estrategias permiten refinar las predicciones de las clases y las ubicaciones de los cuadros, utilizando incluso varias redes de atención de múltiples cabezas ⁷⁹. Estos enfoques han sido aproximados para el cáncer de próstata en ⁸⁰³².

1.3. ANTECEDENTES LOCALIZACIÓN DE LESIONES CS-PCA

Para el personal médico radiológico el diagnóstico de lesiones csPCA en imagenología MRI es una tarea compleja que requiere una amplia experticia, y aún teniéndola, persiste gran variabilidad de interpretación dependiendo del lector ⁸¹. El desarrollo de herramientas diagnósticas basadas en computador (CAD, Computer aided diagnosis), y en especial aquellas apoyadas por inteligencia artificial, resultan entonces fundamentales para soportar la detección de lesiones anormales y su correspondiente diagnóstico ²⁵⁸². Para el caso del soporte a labores urológicas, estas herramientas pueden mejorar la especificidad y la eficiencia del experto radiólogo, en especial cuando existen lesiones en zonas difíciles de interpretar, como sucede en lesiones ubicadas en la zona transicional de la próstata ¹³. A razón de ello, estas herramientas pueden contribuir a la reducción de variabilidad inter-lector ⁸³. En los protocolos clínicos existen acuerdos y protocolos clínicos que establecen la importancia de utilizar

⁸⁰ Mehmet Emin SALMAN et al. "Automated prostate cancer grading and diagnosis system using deep learning-based Yolo object detection algorithm". In: *Expert Systems with Applications* 201 (Sept. 2022), p. 117148. DOI: 10.1016/j.eswa.2022.117148.

⁸¹ Jasper J. TWILT et al. "Artificial Intelligence Based Algorithms for Prostate Cancer Classification and Detection on Magnetic Resonance Imaging: A Narrative Review". In: *Diagnostics* 11.6 (May 2021), p. 959. DOI: 10.3390/diagnostics11060959.

⁸² Stephanie A. HARMON et al. "Artificial intelligence at the intersection of pathology and radiology in prostate cancer". In: *Diagnostic and Interventional Radiology* 25.3 (May 2019), pp. 183–188. DOI: 10.5152/dir.2019.19125.

⁸³ Sonia GAUR; Nathan LAY, and Stephanie A. Harmon et AL. "Can computer-aided diagnosis assist in the identification of prostate cancer on prostate MRI? a multi-center, multi-reader investigation". In: *Oncotarget* 9.73 (Sept. 2018), pp. 33804–33817. DOI: 10.18632/oncotarget.26100.

los diferentes parámetros MRI, por la significancia que cada una de ellas brinda para la localización y diagnóstico final ⁸⁴⁵⁰⁸⁵. Es por esto, que las herramientas propuestas deben tener en primer lugar la capacidad de capturar, ubicar y cuantificar patrones radiómicos de importancia, con la finalidad de obtener herramientas óptimas que permitan posteriormente una evaluación final por parte del lector ⁸⁶. Por consiguiente, se introducirán a continuación herramientas de localización y detección propuestas a la fecha.

Una primera aproximación común para esta tarea en imágenes MRI de próstata ha sido el análisis por regiones. En ese sentido, (Qian et al., 2016) propuso un framework que involucraba una interpretación de todas las regiones de la próstata mediante el análisis del contexto en las estructuras de los tejidos ⁶⁵. Por su parte, en ⁶⁶, se incorporó la ponderación de instancias para evitar sesgos con el volumen de cada lesión, así como el uso de delimitaciones manuales de la próstata. Aunque estos dos métodos obtienen buenos resultados, sus estudios fueron realizados con una limitada cantidad de datos, afectando posiblemente su capacidad de generalización y representación. Además, el enfoque de estos se basa en los primeros sistemas de localización de ventana deslizante y clasificadores como bosques de decisión (DTs) y SVM, no especializados en la extracción de características de la imagen para la tarea de localización. Para esto, posteriormente se postularon redes de extremo a extremo que vinculan dos subredes para las tareas de registro y detección mediante la

⁸⁴ Robin SCOTT et al. "PI-RADS v2.1: What has changed and how to report". In: *South African Journal of Radiology* 25.1 (June 2021). DOI: 10.4102/sajr.v25i1.2062.

⁸⁵ Mark WU et al. "Transition zone prostate cancer: Logistic regression and machine-learning models of quantitative ADC, shape and texture features are highly accurate for diagnosis". In: *Journal of Magnetic Resonance Imaging* 50.3 (Jan. 2019), pp. 940–950. DOI: 10.1002/jmri.26674.

⁸⁶ Ahmad ALGOHARY et al. "Radiomic features on MRI enable risk categorization of prostate cancer patients on active surveillance: Preliminary findings". In: *Journal of Magnetic Resonance Imaging* 48.3 (Feb. 2018), pp. 818–828. DOI: 10.1002/jmri.25983.

introducción de CNNs ⁸⁷⁸⁸. A pesar de alcanzar buenos resultados en cuanto a sensibilidad y especificidad, el primero enuncia valores bajos de especificidad, que podría inducir errores, hasta someter pacientes a tratamientos innecesarios, mientras el segundo muestra una baja sensibilidad, que podría desestimar pacientes con lesiones significativas que requieran atención y tratamiento. A partir de esto, otros trabajos propusieron enfoques similares, destinando redes CNN extremo a extremo en sus desarrollos ⁸⁹⁹⁰⁹¹. Así mismo, se han propuesto trabajos que buscan alcanzar una mejor localización utilizando información mapeada desde imágenes histopatológicas ⁷³³², inclusive, autores como (Salman et al., 2022) han propuesto el uso de la herramienta YOLO, para maniobrar la localización del cáncer de próstata ⁸⁰. Sin embargo, estos enfoques involucran el registro de imágenes MRI e histopatológicas, lo cual puede carecer de una buena congruencia y verse afectado por una mala correspondencia entre las imágenes. Por otra parte, la evolución de diferentes estrategias en CNNs ha permitido que emerjan nuevos métodos, por ejemplo, involucrando módulos residuales, utilizando transfer learning, e incluso, incluyendo mecanismos de atención para

-
- ⁸⁷ Minh Hung LE et al. “Automated diagnosis of prostate cancer in multi-parametric MRI based on multimodal convolutional neural networks”. In: *Physics in Medicine & Biology* 62.16 (July 2017), pp. 6497–6514. DOI: 10.1088/1361-6560/aa7731.
- ⁸⁸ Zhiwei WANG et al. “Automated Detection of Clinically Significant Prostate Cancer in mp-MRI Images Based on an End-to-End Deep Neural Network”. In: *IEEE Transactions on Medical Imaging* 37.5 (May 2018), pp. 1127–1139. DOI: 10.1109/tmi.2017.2789181.
- ⁸⁹ Junichiro ISHIOKA et al. “Computer-aided diagnosis of prostate cancer on magnetic resonance imaging using a convolutional neural network algorithm”. In: *BJU International* 122.3 (June 2018), pp. 411–417. DOI: 10.1111/bju.14397.
- ⁹⁰ Yohan SUMATHIPALA; Nathan LAY, and Baris TURKBELY. “Prostate cancer detection from multi-institution multiparametric MRIs using deep convolutional neural networks”. In: *Journal of Medical Imaging* 5.04 (Dec. 2018), p. 1. DOI: 10.1117/1.jmi.5.4.044507.
- ⁹¹ Ruiming CAO et al. “Joint Prostate Cancer Detection and Gleason Score Prediction in mp-MRI via Focal-Net”. In: *IEEE Transactions on Medical Imaging* 38.11 (Nov. 2019), pp. 2496–2506. DOI: 10.1109/tmi.2019.2901928.

segmentación ⁴⁵⁹²⁹³. No obstante, este último enfoque no alcanza resultados satisfactorios, sugieren que es necesario un conjunto de datos óptimos con buen procesamiento, e incluso que incluya estudios de diferentes centros para capturar mejor la alta variabilidad que concierne a las lesiones prostáticas en MRI ⁹³. Además, explicitan que tareas de clasificación de lesiones no parecerían muy adecuadas, pues es ciertamente subjetiva y dificulta la tarea de segmentar la lesión. Enfoques similares de segmentación, como los modelos Panópticos ⁴⁵, donde metodología semántica y segmentación de instancias fueron involucradas, arrojaron mejoras en el rendimiento de detección. De la misma manera, existen abordajes 3D, donde buscan enfocarse en características relevantes en múltiples resoluciones a través de mecanismos de atención y CNNs 3D ⁹⁴, así mismo, involucran información de dominio clínico para sus desarrollos. También, los autores resaltan la importancia de diversificar en herramientas CAD que resulten menos dependientes a los conjuntos de datos. Recientemente, se han decantado por aproximarse a soluciones retomando métodos de KNN, donde se refieren a matrices de concurrencia, o reducción de ruidos por transformaciones, hasta clasificadores tradicionales ⁹⁵. Sin embargo, es claro que estructuras especializadas en imágenes han mostrado ser más eficientes. Otras soluciones involucran

⁹² Adeel Ahmed ABBASI et al. “Detecting prostate cancer using deep learning convolution neural network with transfer learning approach”. In: *Cognitive Neurodynamics* 14.4 (Apr. 2020), pp. 523–533. DOI: 10.1007/s11571-020-09587-5.

⁹³ Sherif MEHRALIVAND et al. “Multicenter Multireader Evaluation of an Artificial Intelligence–Based Attention Mapping System for the Detection of Prostate Cancer With Multiparametric MRI”. in: *American Journal of Roentgenology* 215.4 (Oct. 2020), pp. 903–912. DOI: 10.2214/ajr.19.22573.

⁹⁴ Anindo SAHA; Matin HOSSEINZADEH, and Henkjan HUISMAN. “End-to-end prostate cancer detection in bpMRI via 3D CNNs: Effects of attention mechanisms, clinical priori and decoupled false positive reduction”. In: *Medical Image Analysis* 73 (Oct. 2021), p. 102155. DOI: 10.1016/j.media.2021.102155.

⁹⁵ L. ANAND et al. “Diagnosis of Prostate Cancer Using GLCM Enabled KNN Technique by Analyzing MRI Images”. In: *BioMed Research International* 2023 (Jan. 2023). Ed. by Gaganpreet KAUR, pp. 1–7. DOI: 10.1155/2023/3913351.

esquemas adversarios-generativos (Gans, por sus siglas en Inglés) ⁹⁶. No obstante, su propuesta desestiman las características radiómicas variopintas al no involucrar secuencias anatómicas y funcionales MRI, donde en la práctica médica, y además, en bpMRI, ninguna es sustitutoria.

De esta manera, es evidente que, aunque los desarrollos relacionados con la detección de lesiones CsPCA son importantes, su enfoque propositivo de frameworks propios y esfuerzos en tareas de clasificación, podrían llevar a un descuido o desaprovechamiento de las herramientas de localización que conforman el estado del arte, las cuales han sido probadas y validadas por la comunidad académica y han demostrado ser efectivas y confiables.

⁹⁶ Alexandros PATSANIS et al. "A comparison of Generative Adversarial Networks for automated prostate cancer detection on T2-weighted MRI". in: *Informatics in Medicine Unlocked* 39 (2023), p. 101234. DOI: 10.1016/j.imu.2023.101234.

2. PROBLEMA DE INVESTIGACIÓN

El cáncer de próstata es una enfermedad que afecta a un gran número de hombres en todo el mundo y su detección temprana es crucial para reducir la agresividad y la cantidad de muertes asociadas. Aunque el estudio de lesiones prostáticas mediante resonancia magnética biparamétrica (bp-MRI) es un criterio estándar para la detección y diagnóstico del cáncer de próstata, la localización de estas lesiones sigue siendo subjetiva a la experticia del radiólogo y su caracterización reporta bajos niveles de sensibilidad. Además, hay diferencias notables entre el diagnóstico por parte de diferentes expertos. Lo cual ha ampliado la necesidad de personal con amplia experiencia, lo que resulta insuficiente para satisfacer la alta demanda de pacientes. Por lo tanto, resulta crucial el desarrollo de herramientas computacionales que permitan la localización automática, precisa y eficiente de lesiones prostáticas. En particular, resulta relevante la implementación de una herramienta basada en aprendizaje profundo que especialice la tarea de localización, para servir de soporte y mejorar el diagnóstico del cáncer de próstata clínicamente significativo csPCA en estudios de bp-MRI.

3. OBJETIVOS

Objetivo General

Desarrollar una estrategia de aprendizaje profundo para la localización de regiones clínicamente significativas de cáncer de próstata (csPCa) en secuencias multimodales MRI biparamétricas (bp-MRI).

Objetivo Específicos

- Acondicionar un conjunto de datos con estudios que incluyan al menos dos secuencias MRI de la glándula prostática junto con sus respectivas anotaciones por expertos radiólogos.
- Adaptar una arquitectura de aprendizaje profundo para llevar a cabo la localización de lesiones prostáticas clínicamente significativas desde secuencias bp-MRI.
- Implementar una estrategia de entrenamiento para la localización de lesiones prostáticas clínicamente significativas en secuencias bp-MRI.
- Evaluar el desempeño de la estrategia propuesta en cuanto a la capacidad de localizar lesiones prostáticas clínicamente significativas.

4. MÉTODO PROPUESTO

4.1. Conjunto de datos de lesiones de Próstata

Para el desarrollo de este trabajo, se consideró la cohorte de datos de entrenamiento y desarrollo público ⁹⁷ contenida en el conglomerado PI-CAI (Prostate Imaging: Cancer AI) ⁹⁸. Este conjunto de datos es relevante por ser multicentro y multi-equipo. Las secuencias se capturaron en tres centros médicos de los Países Bajos: *Radboud University Medical Center* (RUMC), *Ziekenhuis Groep Twente* (ZGT), *University Medical Center Groningen* (UMCG), en equipos de fabricantes Siemens Healthineers o Philips Medical Systems, con diferentes intensidades de campo (1.5T o 3T). Es longitudinal en el tiempo, con casos de estudio fechados entre 2012 y 2021; homogéneo en sus protocolos, la adquisición se siguió a detalle con lo indicado en el protocolo de imagenología ⁹⁹; e interdisciplinar, en su diseño se contó con un consejo asesor científico internacional compuesto por dieciséis expertos en IA de próstata, radiología y urología.

De la misma manera, estos estudios de resonancia bp-mRI cuentan con las respectivas anotaciones de lesión. Esto implica una segmentación a nivel de vóxel que demarca zonas específicas o regiones dentro de la glándula prostática o en el tejido circundante, así como una posible graduación de la lesión. Estas tareas son realizadas por un profesional capacitado con más de 20 años de experiencia, o un residente bajo la supervisión de un radiólogo.

⁹⁷ Anindo SAHA et al. *The PI-CAI Challenge: Public Training and Development Dataset*. en. 2022. DOI: 10.5281/ZENODO.6517398.

⁹⁸ Joeran S. Bosma Bram van Ginneken Derya Yakar Mattijs Elschot Jeroen Veltman Jurgen Fütterer Maarten de Rooij Henkjan Huisman ANINDO SAHA Jasper J. Twilt. "Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge". In: (2022). DOI: 10.5281/zenodo.6522364.

⁹⁹ Rianne R.M. ENGELS et al. "Multiparametric Magnetic Resonance Imaging for the Detection of Clinically Significant Prostate Cancer: What Urologists Need to Know. Part 1: Acquisition". In: *European Urology* 77.4 (Apr. 2020), 457–468. DOI: 10.1016/j.eururo.2019.09.021.

Para lo anterior, se basan en el protocolo de anotación PI-RADS (Prostate Imaging Reporting and Data System), siguiendo las instrucciones de su última versión, la 2.1 ⁸⁴. Por otra parte, es importante mencionar el protocolo ISUP (Histopathological grading of prostate cancer). Aunque ambos protocolos buscan la determinación y estratificación de una lesión prostática y trabajan en el mismo rango [1,5], esto no significa que sean comparables. El protocolo ISUP se destina al reporte únicamente de componentes histológicos, que están en etapas subsecuentes del protocolo de atención; no así las radiológicas que son las establecidas para atención inicial y screening poblacional. Es decir, en este conjunto de datos, los *ground truths* de las lesiones, aunque en un primer momento están determinadas por el radiólogo, se han verificado con el segundo protocolo para confirmar su naturaleza. De acuerdo a lo anterior, se estableció que son casos de estudio positivos aquellos confirmados histológicamente con la denominación ISUP \geq 2, y negativos aquellos con ISUP \leq 1 o cuya bm-MRI se haya determinado \leq 2 y no tengan seguimiento.

En ese sentido, PI-CAI (Prostate Imaging: Cancer AI), cuenta con un total de 1,500 casos de estudio, donde se incluyen además casos del denominado PROSTATEx ¹⁰⁰, un conjunto precedente de similares características. De todos los casos de estudio, 425 son los que han sido determinados como positivos, con lesión csPCA, pero únicamente 220 son aquellos que están provistos de una marcación asociada, según el estándar ya comentado.

4.2. Procesamiento de datos

En el contexto de este estudio, cada secuencia de los casos de estudio fue sometida a un proceso de preprocesamiento. Para esto, se utilizaron herramientas estandarizadas pro-

¹⁰⁰ Samuel G. ARMATO et al. "PROSTATEx Challenges for computerized classification of prostate lesions from multiparametric magnetic resonance images". In: *Journal of Medical Imaging* 5.04 (Nov. 2018), p. 1. DOI: 10.1117/1.jmi.5.4.044501.

porcionadas por el pipeline general descrito en ¹⁰¹. Inicialmente, se aplicaron ciertos remuestreos a algunas propiedades de las imágenes; Entre ellos, se modificó el espaciado de los vóxeles a 0.5, 0.5, 3.0 mm y se estableció un tamaño espacial de matriz de 384x384x24. Además, para el nuevo tamaño de imagen, se tuvo en cuenta centrarse en la glándula prostática. Posteriormente, se alineó cada una de las secuencias contenidas en los casos de estudio con su secuencia principal establecida, en este caso la T2W. Por otra parte, se tuvo en cuenta la información de metadatos de cada secuencia para alinear las posibles discrepancias en los vóxeles. Finalmente, se verificó que no existieran errores posibles durante el remuestreo para las anotaciones. Esto incluye, por ejemplo, verificar que la conectividad de las lesiones entre slices no haya sido modificada o que el número de lesiones csPCa no discrepe.

Consecuentemente, en el proceso de preparación de los datos para el entrenamiento del modelo, se examinó a nivel de slice cada secuencia de los casos estudio, para identificar aquellos con región csPCA. Al margen de lo anterior, nos valimos de una segmentación apta, exclusiva de la glándula prostática, referida por el algoritmo¹⁰¹, entrenado mediante anotaciones de glándulas prostáticas de ¹⁰². La finalidad del uso de estas segmentaciones es concurrir en áreas prostáticas de interés, mucho más centradas en el órgano, eliminando el ruido de fondo o artefactos.

El procedimiento se sigue así: para los slices donde se correlacionaba una anotación de glándula se establecía un cuadro delimitador de 150 x 150 píxeles, manteniendo el centro glandular constante, proporcionando así un contexto más amplio y garantizando posibles lesiones muy periféricas.

¹⁰¹ Anindo SAHA et al. *Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge (Study Protocol)*. en. 2022. DOI: 10.5281/ZENODO.6522364.

¹⁰² Renato CUOCOLO et al. "Quality control and whole-gland, zonal and lesion annotations for the PROSTA-TEEx challenge public dataset". In: *European Journal of Radiology* 138 (May 2021), p. 109647. DOI: 10.1016/j.ejrad.2021.109647.

Por lo demás, estas áreas extraídas se utilizaron como máscaras de recorte y se aplicaron tanto a los slices caso de estudio bpMRI, así como a las anotaciones de lesión. Estas nuevas áreas de los slices de cada secuencia se normalizaron y se combinaron para formar una imagen RGB, es decir, se involucró cada secuencia (T2W, HBV Y ADC) en un canal en la imagen resultante. Estas imágenes RGB son las que constituyen el dataset final de entrenamiento.

En cuanto a las anotaciones de lesión csPCA, indicadas por radiología, se realizó un aumento del 30% del cuadro que delimita la lesión csPCA marcada por el radiólogo, manteniendo el centro constante, normalizando las coordenadas del cuadro delimitador. Adicionalmente, se llevó a cabo un mapeo de estos cuadros delimitadores csPCA, en el formato [Presencia de lesión, coordenada_X, Coordenada_Y, Alto, Ancho]. Este formato de las anotaciones clarifica de mejor manera las ubicaciones o áreas de interés csPCA, asegurando que se cuente con la información más relevante para la utilización en modelos de localización.

4.3. Red de localización de lesiones significativas de cáncer de Próstata

La red propuesta para la localización de lesiones significativas de cáncer de próstata (csPCA) se basa en la arquitectura YOLOv5 y sigue una metodología de tres etapas: extracción de características, cuello y cabeza.

En la etapa de extracción de características, se procesa la imagen de entrada para obtener mapas de características de alto nivel. Estos mapas son representaciones de la imagen original que capturan detalles como bordes, texturas y patrones. Estos detalles son cruciales para la identificación de lesiones csPCA. A medida que la imagen se reduce en tamaño, el número de canales de los mapas de características aumenta. Esto permite a la red aprender y representar diferentes granularidades de las lesiones, lo que ayuda en la generalización y en el manejo de la heterogeneidad inherente de las lesiones.

La etapa del cuello implementa estrategias de PANET para realizar submuestreos estratégi-

cos. Esto permite a la red trabajar con diferentes resoluciones y garantiza que los mapas de características tengan un buen valor semántico. Además, se utiliza el arquetipo SPPF (Spatial Pyramid Pooling Fusion), que mejora la funcionalidad del campo receptivo y permite una mayor fluidez en la red. El campo receptivo se refiere a la región en la imagen de entrada que una neurona particular puede “ver”. Al aumentar el campo receptivo, la red puede capturar detalles a diferentes escalas, lo que es crucial para la detección de lesiones de diferentes tamaños.

Finalmente, en la etapa de la cabeza, la red genera las predicciones de localización, existencia y categoría de las lesiones csPCA a partir de los resultados de las etapas anteriores. Esto se realiza mediante capas completamente conectadas (fully connected), que también realizan cálculos para el ajuste correcto de las localizaciones de los cuadros delimitadores. Estas capas predicen la localización, la existencia y la categoría del objeto (en este caso, las lesiones csPCA).

En la Figura (4) se puede observar el pipeline completo de la red.

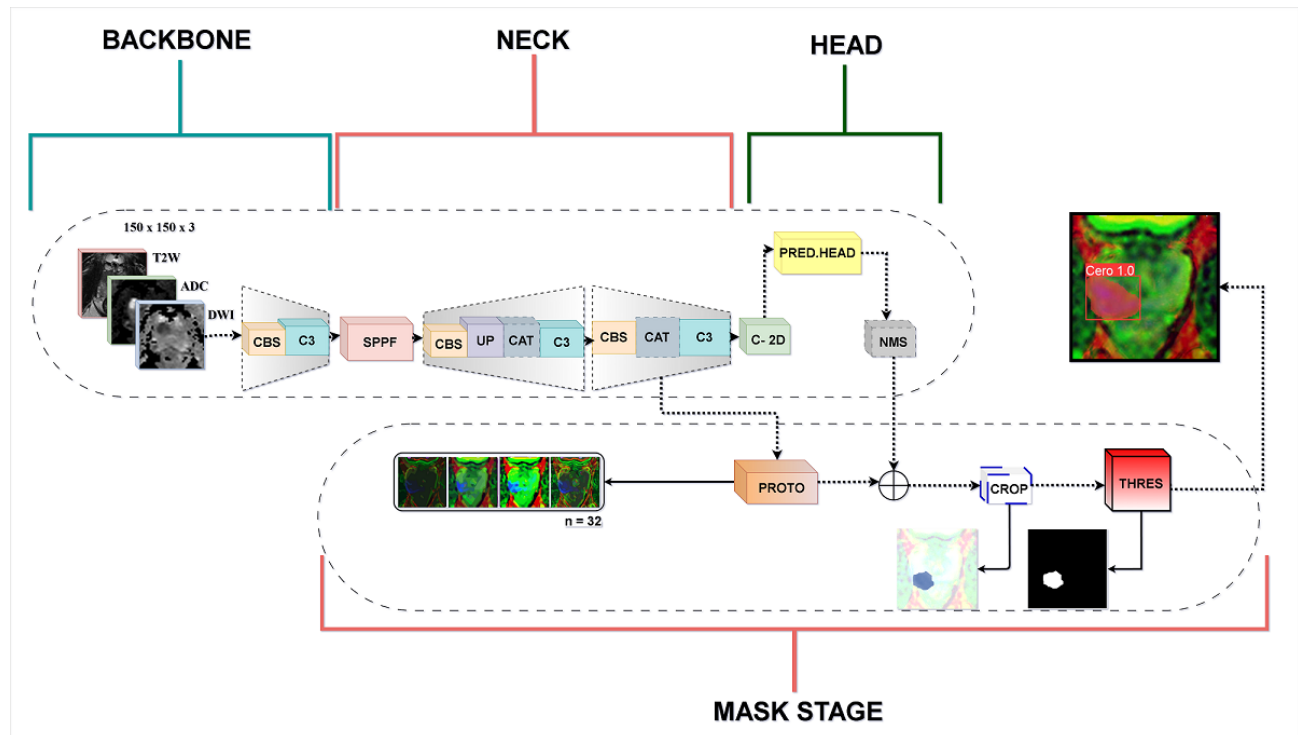
4.4. Extracción de características

La primera parte de la red, está basada en el estándar CSP-NET, llamativo por implementar el formato de división y fusión entrelazada, que permite una mejor propagación de los gradientes a través de la red. La estructura de la red es modular, destacando los bloques CBF y los bloques convolucionales C3. Los bloques CBF actúan como catalizadores de los bloques C3, permitiéndoles extraer características enmiendables.

En este sentido se sigue una serie de etapas que incluyen cinco reducciones convolucionales y cuatro bloques C3. En la Figura ??, se muestra la secuencia de módulos que componen el modelo.

La primera capa convolucional toma la imagen de entrada y aplica 64 filtros de 6x6 con un stride de 2, reduciendo a la mitad la dimensión espacial de la imagen. La siguiente capa convolucional aplica 128 filtros de 3x3 con un stride de 2, disminuyendo nuevamente a la

Figura 4. Estructura del backbone de la red de localización de csPCA



Nota:

mitad la dimensión espacial de la imagen.

A continuación, se introduce el módulo C3, que es un cuello de botella CSP con 3 capas convolucionales. Este módulo realiza una convolución en el tensor de entrada y concatena el resultado con el mismo tensor pasado a través de una convolución y una serie de capas de cuello de botella.

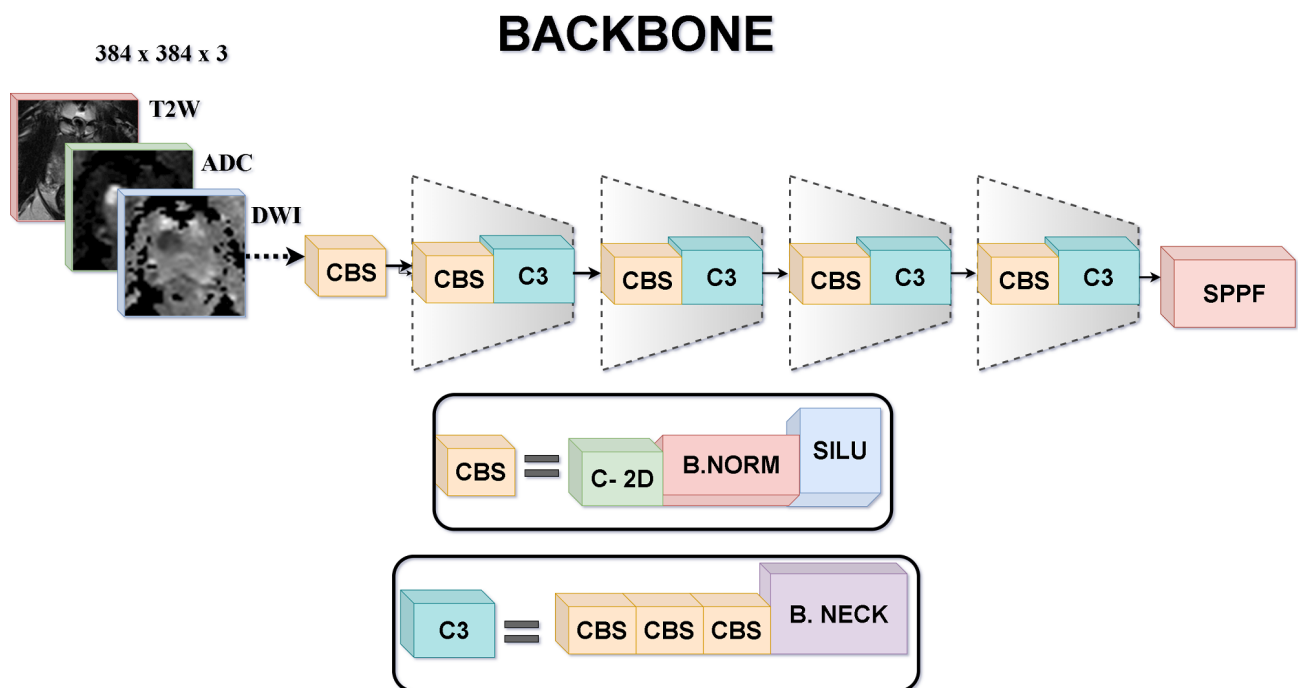
Otra capa convolucional aplica 256 filtros de 3×3 con un stride de 2, reduciendo la dimensión espacial de la imagen a la mitad. Se introduce otro módulo C3, similar al anterior pero con 256 canales.

Una capa convolucional que aplica 512 filtros de 3×3 con un stride de 2, reduce la dimensión espacial de la imagen a la mitad. Se introduce otro módulo C3, similar a los anteriores pero con 512 canales.

Una capa convolucional que aplica 1024 filtros de 3x3 con un stride de 2, reduce la dimensión espacial de la imagen a la mitad. Se introduce otro módulo C3, similar a los anteriores pero con 1024 canales.

Finalmente, se introduce el módulo SPPF (Spatial Pyramid Pooling Fusion), el cual es una versión optimizada de los comunes módulos SPP que tiene igual funcionalidad matemática y menos operaciones de punto flotante (FLOPs). El propósito de SPPF es cohesionar una representación a múltiples escalas de los mapas de características primigenios.

Figura 5. Pipeline General para la localización de lesiones csPCA



Nota:

4.5. Predicción de regiones

4.6. Contorno de lesiones para la tarea de localización

En el procesamiento de imágenes médicas, la identificación precisa de las regiones de interés (ROI) es un componente crítico para el rendimiento óptimo de los modelos de aprendizaje automático. Así pues, se implementó un enfoque alternativo para el tratamiento de las anotaciones de las regiones con lesiones csPCA. En lugar de expandir el cuadro que delimita la lesión del radiólogo un 30% normalizado, este enfoque implica la identificación de los puntos del perímetro de la lesión csPCA marcada por el radiólogo. Estos puntos se dilatan morfológicamente 5 píxeles, asegurando así que toda la lesión esté incluida. Posteriormente, se normalizan en relación con el tamaño de la máscara de referencia. Este enfoque ofrece una representación detallada de la lesión, lo cual puede potenciar la capacidad del modelo para aprender características relevantes. En términos más detallados, los puntos del perímetro de la lesión se mapean en el formato [Presencia de lesión, coordenada_X1, Coordenada_Y1, ..., coordenada_Xn, Coordenada_Yn]. Este formato de anotaciones proporciona una representación precisa de las áreas de interés csPCA, asegurando que se disponga de la información más relevante para su uso en modelos de localización.

5. DISEÑO EXPERIMENTAL

Secuencia	Precisión	Recall	Ap0.5	Ap .05-095
T2W	0.394	0.282	0.215	0.0543
ADC	0.745	0.436	0.479	0.184
DWI	0.669	0.342	0.429	0.163
T2W-ADC-DWI	0.74	0.496	0.566	0.251
T2W-ADC-DWI-(150_150)	0.514	0.479	0.56	0.251
T2W-ADC-DWI-SEG-(150_150)	0.899	0.475	0.693	0.377

Tabla 1. Comparativa de la utilización de diferentes secuencias

Threshold IOUV	Precisión	Recall	ApThreshold-0.95	ApThreshold-0.95
0.1	0.673	0.627	0.727	0.523
0.2	0.673	0.627	0.727	0.503
0.3	0.902	0.5	0.722	0.468
0.4	0.664	0.619	0.721	0.433
0.5	0.899	0.475	0.693	0.377
0.6	0.851	0.449	0.63	0.3
0.7	0.692	0.364	0.497	0.204
0.8	0.453	0.186	0.233	0.0969
0.9	0	0	0	0

Tabla 2. T2W-ADC-DWI-SEG-(150_150) por Thresholds IOUv

6. EVALUACIÓN Y RESULTADOS

7. CONCLUSIONES Y TRABAJO FUTURO

BIBLIOGRAFÍA

ABBASI, Adeel Ahmed et al. “Detecting prostate cancer using deep learning convolution neural network with transfer learning approach”. In: *Cognitive Neurodynamics* 14.4 (Apr. 2020), pp. 523–533. DOI: 10.1007/s11571-020-09587-5 (cit. on p. 32).

ABDELRAZEK, Ahmad et al. “Recent Advances in Prostate Cancer (PCa) Diagnostics”. In: *Uro* 2.2 (2022), pp. 109–121. DOI: 10.3390/uro2020014 (cit. on p. 11).

ALGOHARY, Ahmad et al. “Radiomic features on MRI enable risk categorization of prostate cancer patients on active surveillance: Preliminary findings”. In: *Journal of Magnetic Resonance Imaging* 48.3 (Feb. 2018), pp. 818–828. DOI: 10.1002/jmri.25983 (cit. on p. 30).

ALVER, Kadir Han et al. “Comparison of Multiparametric and Fast scpMRI/scp Protocols in Detecting Clinically Significant Prostate Cancer and a Detailed Cost Analysis”. In: *Journal of Magnetic Resonance Imaging* 56.5 (Mar. 2022), pp. 1437–1447. DOI: 10.1002/jmri.28142 (cit. on p. 14).

ANAND, L. et al. “Diagnosis of Prostate Cancer Using GLCM Enabled KNN Technique by Analyzing MRI Images”. In: *BioMed Research International* 2023 (Jan. 2023). Ed. by Gaganpreet KAUR, pp. 1–7. DOI: 10.1155/2023/3913351 (cit. on p. 32).

ANINDO SAHA Jasper J. Twilt, Joeran S. Bosma Bram van Ginneken Derya Yakar Mattijs Elschot Jeroen Veltman Jurgen Fütterer Maarten de Rooij Henkjan Huisman. “Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge”. In: (2022). DOI: 10.5281/zenodo.6522364 (cit. on pp. 20, 22, 23, 36).

ARMATO, Samuel G. et al. “PROSTATEx Challenges for computerized classification of prostate lesions from multiparametric magnetic resonance images”. In: *Journal of Medical Imaging* 5.04 (Nov. 2018), p. 1. DOI: 10.1117/1.jmi.5.4.044501 (cit. on p. 37).

ASÍ VAMOS EN SALUD. *Mortalidad por Cáncer de Próstata*. <https://asivamosensalud.org/indicadores/enfermedades-cronicas-no-transmisibles/tasa-cancer-prostata-georeferenciado>. 2021 (cit. on p. 11).

BARA, M. Teresa Gracia et al. “Hypersensitivity to Gadolinium-Based Contrast Media”. In: *Frontiers in Allergy* 3 (Mar. 2022). DOI: 10.3389/falgy.2022.813927 (cit. on p. 13).

BARRETT, Tristan et al. “Quality checkpoints in the MRI-directed prostate cancer diagnostic pathway”. In: *Nature Reviews Urology* 20.1 (Sept. 2022), pp. 9–22. DOI: 10.1038/s41585-022-00648-4 (cit. on p. 18).

BEHZADI, Ashkan Heshmatzadeh et al. “Immediate Allergic Reactions to Gadolinium-based Contrast Agents: A Systematic Review and Meta-Analysis”. In: *Radiology* 286.2 (Feb. 2018), pp. 471–482. DOI: 10.1148/radiol.2017162740 (cit. on p. 13).

BEYER, Thomas et al. “PI-RADS 2.1 – Image Interpretation: The Most Important Updates and Their Clinical Implications”. In: *RöFo - Fortschritte auf dem Gebiet der Röntgenstrahlen und der bildgebenden Verfahren* (Dec. 2020). DOI: 10.1055/a-1324-4010 (cit. on p. 18).

BRATT, Ola et al. “Screening for prostate cancer: evidence, ongoing trials, policies and knowledge gaps”. In: *BMJ Oncology* 2.1 (Apr. 2023), e000039. DOI: 10.1136/bmjonc-2023-000039 (cit. on p. 15).

CAGLIC, Iztok and BARRETT, Tristan. “Diffusion-weighted imaging (DWI) in lymph node staging for prostate cancer”. In: *Translational Andrology and Urology* 7.5 (Oct. 2018), pp. 814–823. DOI: 10.21037/tau.2018.08.04 (cit. on p. 21).

CAO, Ruiming et al. “Joint Prostate Cancer Detection and Gleason Score Prediction in mp-MRI via FocalNet”. In: *IEEE Transactions on Medical Imaging* 38.11 (Nov. 2019), pp. 2496–2506. DOI: 10.1109/tmi.2019.2901928 (cit. on p. 31).

CARION, Nicolas et al. *End-to-End Object Detection with Transformers*. 2020. DOI: 10.48550/ARXIV.2005.12872 (cit. on pp. 27, 29).

CHEN, Quan et al. “A Transfer Learning Approach for Malignant Prostate Lesion Detection on Multiparametric MRI”. In: *Technology in Cancer Research & Treatment* 18 (Jan. 2019), p. 153303381985836. DOI: 10.1177/1533033819858363 (cit. on p. 16).

CUOCOLO, Renato et al. “Quality control and whole-gland, zonal and lesion annotations for the PROSTATEx challenge public dataset”. In: *European Journal of Radiology* 138 (May 2021), p. 109647. DOI: 10.1016/j.ejrad.2021.109647 (cit. on p. 38).

DAI, Z. et al. “Accurate Prostate Cancer Detection and Segmentation Using Non-Local Mask R-CNN With Histopathological Ground Truth”. In: *International Journal of Radiation Oncology*Biology*Physics* 111.3 (Nov. 2021), S45. DOI: 10.1016/j.ijrobp.2021.07.123 (cit. on pp. 26, 31).

DALAL, N. and TRIGGS, B. “Histograms of Oriented Gradients for Human Detection”. In: *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*. IEEE. DOI: 10.1109/cvpr.2005.177 (cit. on p. 25).

DAVID, Michael and LESLIE, Stephen. “Prostate specific antigen”. In: *StatPearls* (2022) (cit. on p. 12).

DE CROON, G. “Active object detection”. In: vol. IU. MTSV/-. 2007, 97 – 103 (cit. on p. 24).

DE ROOIJ, M. “Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: preliminary results from the PI-CAI Challenge”. In: *Preliminary results from the PI-CAI Challenge*. EAU 2023. Milan, Italia.: EAU 2023 Prostate Cancer, 2023 (cit. on p. 19).

DENIFFEL, Dominik et al. “Avoiding Unnecessary Biopsy: MRI-based Risk Models versus a PI-RADS and PSA Density Strategy for Clinically Significant Prostate Cancer”. In: *Radiology* 300.2 (Aug. 2021), pp. 369–379. DOI: 10.1148/radiol.2021204112 (cit. on p. 12).

DU, Xianzhi et al. *SpineNet: Learning Scale-Permuted Backbone for Recognition and Localization*. 2019. DOI: 10.48550/ARXIV.1912.05027 (cit. on pp. 27, 28).

ELDRED-EVANS, David et al. “Population-Based Prostate Cancer Screening With Magnetic Resonance Imaging or Ultrasonography: The IP1-PROSTAGRAM Study”. In: *JAMA Oncology* 7.3 (Mar. 2021), pp. 395–402. DOI: 10.1001/jamaoncol.2020.7456. eprint: https://jamanetwork.com/journals/jamaoncology/articlepdf/2776224/jamaoncology_eldredevans_2021_oi_200109_1615397512.10777.pdf (cit. on p. 13).

ENGELS, Rianne R.M. et al. “Multiparametric Magnetic Resonance Imaging for the Detection of Clinically Significant Prostate Cancer: What Urologists Need to Know. Part 1: Acquisition”. In: *European Urology* 77.4 (Apr. 2020), 457–468. DOI: 10.1016/j.eururo.2019.09.021 (cit. on p. 36).

FERNANDES, Maria Clara et al. “The role of MRI in prostate cancer: current and future directions”. In: *Magnetic Resonance Materials in Physics, Biology and Medicine* 35.4 (Mar. 2022), pp. 503–521. DOI: 10.1007/s10334-022-01006-6 (cit. on p. 18).

FÜTTERER, Jurgen J. et al. “Can Clinically Significant Prostate Cancer Be Detected with Multiparametric Magnetic Resonance Imaging? A Systematic Review of the Literature”. In:

European Urology 68.6 (Dec. 2015), pp. 1045–1053. DOI: 10.1016/j.eururo.2015.01.013 (cit. on p. 12).

GAUR, Sonia; LAY, Nathan, and AL., Stephanie A. Harmon et. “Can computer-aided diagnosis assist in the identification of prostate cancer on prostate MRI? a multi-center, multi-reader investigation”. In: *Oncotarget* 9.73 (Sept. 2018), pp. 33804–33817. DOI: 10.18632/oncotarget.26100 (cit. on p. 29).

GIRSHICK, Ross. *Fast R-CNN*. 2015. DOI: 10.48550/ARXIV.1504.08083 (cit. on p. 26).

GIRSHICK, Ross et al. “Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation”. In: *2014 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE, June 2014. DOI: 10.1109/cvpr.2014.81 (cit. on p. 25).

GROARKE, AnnMarie et al. “Quality of life and adjustment in men with prostate cancer: Interplay of stress, threat and resilience”. In: *PLOS ONE* 15.9 (Sept. 2020). Ed. by Ali MONTAZERI, e0239469. DOI: 10.1371/journal.pone.0239469 (cit. on p. 17).

HAMDY, Freddie C.; DONOVAN, Jenny L., and AL., J. Athene Lane et. “Fifteen-Year Outcomes after Monitoring, Surgery, or Radiotherapy for Prostate Cancer”. In: *New England Journal of Medicine* 388.17 (Apr. 2023), pp. 1547–1558. DOI: 10.1056/nejmoa2214122 (cit. on p. 15).

HARMON, Stephanie A. et al. “Artificial intelligence at the intersection of pathology and radiology in prostate cancer”. In: *Diagnostic and Interventional Radiology* 25.3 (May 2019), pp. 183–188. DOI: 10.5152/dir.2019.19125 (cit. on p. 29).

HE, Kaiming et al. *Mask R-CNN*. 2017. DOI: 10.48550/ARXIV.1703.06870 (cit. on p. 26).

HMIDANI, O. and ISMAILI ALAOUI, E. M. “A comprehensive survey of the R-CNN family for object detection”. In: *2022 5th International Conference on Advanced Communication Technologies and Networking (CommNet)*. 2022, pp. 1–6. DOI: 10.1109/CommNet56067.2022.9993862 (cit. on p. 25).

ISHIOKA, Junichiro et al. “Computer-aided diagnosis of prostate cancer on magnetic resonance imaging using a convolutional neural network algorithm”. In: *BJU International* 122.3 (June 2018), pp. 411–417. DOI: 10.1111/bju.14397 (cit. on p. 31).

JACOBS, Michael A et al. “Diffusion weighted imaging with ADC mapping and spectroscopy in prostate cancer”. In: *Topics in magnetic resonance imaging: TMRI* 19.6 (2008), p. 261 (cit. on p. 22).

JENSEN, Carina et al. “Assessment of prostate cancer prognostic Gleason grade group using zonal-specific features extracted from biparametric MRI using a KNN classifier”. In: *Journal of Applied Clinical Medical Physics* 20.2 (Feb. 2019), pp. 146–153. DOI: 10.1002/acm2.12542 (cit. on p. 16).

KANG, Hyunseon C. et al. “Accuracy of Prostate Magnetic Resonance Imaging: Reader Experience Matters”. In: *European Urology Open Science* 27 (May 2021), pp. 53–60. DOI: 10.1016/j.euros.2021.03.004 (cit. on p. 14).

KOH, Dow-Mu and COLLINS, David J. “Diffusion-Weighted MRI in the Body: Applications and Challenges in Oncology”. In: *American Journal of Roentgenology* 188.6 (June 2007), pp. 1622–1635. DOI: 10.2214/ajr.06.1403 (cit. on p. 21).

LAHOTI, Amol Madanlal et al. “Role and application of diffusion-weighted imaging in evaluation of prostate cancer”. In: *Indian Journal of Medical and Paediatric Oncology* 39.03 (2018), pp. 349–354 (cit. on p. 21).

LAY, Nathan et al. “Detection of prostate cancer in multiparametric MRI using random forest with instance weighting”. In: *Journal of Medical Imaging* 4.2 (June 2017), p. 024506. DOI: 10.1117/1.jmi.4.2.024506 (cit. on pp. 25, 30).

LE, Minh Hung et al. “Automated diagnosis of prostate cancer in multi-parametric MRI based on multimodal convolutional neural networks”. In: *Physics in Medicine & Biology* 62.16 (July 2017), pp. 6497–6514. DOI: 10.1088/1361-6560/aa7731 (cit. on p. 31).

LIN, Tsung-Yi et al. *Focal Loss for Dense Object Detection*. 2017. DOI: 10.48550/ARXIV.1708.02002 (cit. on pp. 27, 28).

LIU, Wei et al. “SSD: Single Shot MultiBox Detector”. In: *Computer Vision – ECCV 2016*. Springer International Publishing, 2016, pp. 21–37. DOI: 10.1007/978-3-319-46448-0_2 (cit. on pp. 27, 28).

LIU, Zhiyu et al. “A Two-Stage Approach for Automated Prostate Lesion Detection and Classification with Mask R-CNN and Weakly Supervised Deep Neural Network”. In: *Artificial Intelligence in Radiation Therapy*. Springer International Publishing, 2019, pp. 43–51. DOI: 10.1007/978-3-030-32486-5_6 (cit. on p. 26).

LOWE, David G. “Distinctive Image Features from Scale-Invariant Keypoints”. In: *International Journal of Computer Vision* 60.2 (Nov. 2004), pp. 91–110. DOI: 10.1023/b:visi.0000029664.99615.94 (cit. on p. 24).

MATA, Lidia Alcalá et al. “Artificial Intelligence–assisted Prostate Cancer Diagnosis: Radiologic-Pathologic Correlation”. In: *RadioGraphics* 41.6 (Oct. 2021), pp. 1676–1697. DOI: 10.1148/rg.2021210020 (cit. on pp. 14, 15, 29).

MAURER, Martin H and HEVERHAGEN, Johannes T. “Diffusion weighted imaging of the prostate—principles, application, and advances”. In: *Translational andrology and urology* 6.3 (2017), p. 490 (cit. on pp. 21, 22, 30).

MEHRALIVAND, Sherif; YANG, Dong, and AL., Stephanie A. Harmon et. “A Cascaded Deep Learning–Based Artificial Intelligence Algorithm for Automated Lesion Detection and Classification on Biparametric Prostate Magnetic Resonance Imaging”. In: *Academic Radiology* 29.8 (Aug. 2022), pp. 1159–1168. DOI: 10.1016/j.acra.2021.08.019 (cit. on p. 16).

MEHRALIVAND, Sherif et al. “Multicenter Multireader Evaluation of an Artificial Intelligence–Based Attention Mapping System for the Detection of Prostate Cancer With Multiparametric MRI”. In: *American Journal of Roentgenology* 215.4 (Oct. 2020), pp. 903–912. DOI: 10.2214/ajr.19.22573 (cit. on p. 32).

MERRIEL, Samuel W. D. et al. “Systematic review and meta-analysis of the diagnostic accuracy of prostate-specific antigen (PSA) for the detection of prostate cancer in symptomatic patients”. In: *BMC Medicine* 20.1 (Feb. 2022). DOI: 10.1186/s12916-021-02230-y (cit. on p. 12).

MURPHY, Gillian et al. “The expanding role of MRI in prostate cancer”. In: *American Journal of Roentgenology* 201.6 (2013), pp. 1229–1238 (cit. on pp. 13, 19, 29).

NAJI, Leen et al. “Digital Rectal Examination for Prostate Cancer Screening in Primary Care: A Systematic Review and Meta-Analysis”. In: *The Annals of Family Medicine* 16.2 (Mar. 2018), pp. 149–154. DOI: 10.1370/afm.2205 (cit. on p. 12).

OBMANN, Verena C. et al. “Diagnostic Accuracy of a Rapid Biparametric MRI Protocol for Detection of Histologically Proven Prostate Cancer”. In: *Urology* 122 (Dec. 2018), pp. 133–138. DOI: 10.1016/j.urology.2018.08.032 (cit. on p. 14).

PAPAGEORGIOU, Constantine and POGGIO, Tomaso. In: *International Journal of Computer Vision* 38.1 (2000), pp. 15–33. DOI: 10.1023/a:1008162616689 (cit. on p. 24).

PATSANIS, Alexandros et al. “A comparison of Generative Adversarial Networks for automated prostate cancer detection on T2-weighted MRI”. In: *Informatics in Medicine Unlocked* 39 (2023), p. 101234. DOI: 10.1016/j.imu.2023.101234 (cit. on p. 33).

PECORARO, Martina et al. “The future direction of imaging in prostate cancer: MRI with or without contrast injection”. In: *Andrology* 9.5 (June 2021), pp. 1429–1443. DOI: 10.1111/andr.13041 (cit. on p. 14).

“Prostate cancer”. In: *Nursing Standard* 30.40 (June 2016), pp. 17–17. DOI: 10.7748/ns.30.40.17.s20 (cit. on p. 17).

QIAN, Chunjun et al. “In vivo MRI based prostate cancer localization with random forests and auto-context model”. In: *Computerized Medical Imaging and Graphics* 52 (Sept. 2016), pp. 44–57. DOI: 10.1016/j.compmedimag.2016.02.001 (cit. on pp. 25, 30).

REBELLO, Richard J. et al. “Prostate cancer”. In: *Nature Reviews Disease Primers* 7.1 (Feb. 2021). DOI: 10.1038/s41572-020-00243-0 (cit. on p. 17).

REDMON, Joseph et al. *You Only Look Once: Unified, Real-Time Object Detection*. 2015. DOI: 10.48550/ARXIV.1506.02640 (cit. on p. 27).

REN, Shaoqing et al. *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. 2015. DOI: 10.48550/ARXIV.1506.01497 (cit. on p. 26).

REY, Rodolfo Alberto et al. “Male hypogonadism: an extended classification based on a developmental, endocrine physiology-based approach”. In: *Andrology* 1.1 (2013), pp. 3–16 (cit. on p. 17).

RIMMER, Abi. “Radiologist shortage leaves patient care at risk, warns royal college”. In: *BMJ* (Oct. 2017), j4683. DOI: 10.1136/bmj.j4683 (cit. on p. 14).

ROUVIÈRE, Olivier et al. “Artificial intelligence algorithms aimed at characterizing or detecting prostate cancer on MRI: How accurate are they when tested on independent cohorts? – A systematic review”. In: *Diagnostic and Interventional Imaging* 104.5 (May 2023), pp. 221–234. DOI: 10.1016/j.diii.2022.11.005 (cit. on p. 15).

SAAR, Matthias et al. “Current Role of Multiparametric MRI and MRI Targeted Biopsies for Prostate Cancer Diagnosis in Germany: A Nationwide Survey”. In: *Urologia Internationalis* 104.9-10 (2020), pp. 731–740. DOI: 10.1159/000508755 (cit. on p. 13).

SAHA, Anindo; HOSSEINZADEH, Matin, and HUISMAN, Henkjan. “End-to-end prostate cancer detection in bpMRI via 3D CNNs: Effects of attention mechanisms, clinical priori and decoupled false positive reduction”. In: *Medical Image Analysis* 73 (Oct. 2021), p. 102155. DOI: 10.1016/j.media.2021.102155 (cit. on p. 32).

SAHA, Anindo et al. *Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge (Study Protocol)*. en. 2022. DOI: 10.5281/ZENODO.6522364 (cit. on p. 38).

— *The PI-CAI Challenge: Public Training and Development Dataset*. en. 2022. DOI: 10.5281/ZENODO.6517398 (cit. on p. 36).

SALKA, Bassel R. et al. “Effect of Prostate MRI Interpretation Experience on PPV Using PI-RADS Version 2: A 6-Year Assessment Among Eight Fellowship-Trained Radiologists”. In: *American Journal of Roentgenology* 219.3 (Sept. 2022), pp. 453–460. DOI: 10.2214/ajr.22.27421 (cit. on p. 14).

SALMAN, Mehmet Emin et al. “Automated prostate cancer grading and diagnosis system using deep learning-based Yolo object detection algorithm”. In: *Expert Systems with Applications* 201 (Sept. 2022), p. 117148. DOI: 10.1016/j.eswa.2022.117148 (cit. on pp. 29, 31).

SCHOOTS, Ivo G. et al. “PI-RADS Committee Position on MRI Without Contrast Medium in Biopsy-Naive Men With Suspected Prostate Cancer: Narrative Review”. In: *American Journal of Roentgenology* 216.1 (Jan. 2021), pp. 3–19. DOI: 10.2214/ajr.20.24268 (cit. on p. 13).

SCIALPI, Michele et al. “Biparametric MRI of the prostate”. In: *Türk Üroloji Dergisi/Turkish Journal of Urology* 43.4 (Nov. 2017), pp. 401–409. DOI: 10.5152/tud.2017.06978 (cit. on p. 18).

SCOTT, Robin et al. “PI-RADS v2.1: What has changed and how to report”. In: *South African Journal of Radiology* 25.1 (June 2021). DOI: 10.4102/sajr.v25i1.2062 (cit. on pp. 30, 37).

SEETHARAMAN, Arun et al. “Automated detection of aggressive and indolent prostate cancer on magnetic resonance imaging”. In: *Medical Physics* 48.6 (May 2021), pp. 2960–2972. DOI: 10.1002/mp.14855 (cit. on pp. 16, 29, 31).

SHAH, Milap et al. “Current Applications of Artificial Intelligence in Benign Prostatic Hyperplasia”. In: *Türk Üroloji Dergisi/Turkish Journal of Urology* 48.4 (July 2022), pp. 262–267. DOI: 10.5152/tud.2022.22028 (cit. on p. 15).

SMITH, Ryan P. et al. “Identification of Clinically Significant Prostate Cancer by Prostate-Specific Antigen Screening”. In: *Archives of Internal Medicine* 164.11 (June 2004), p. 1227. DOI: 10.1001/archinte.164.11.1227 (cit. on p. 12).

SONI, Mukesh et al. “Light Weighted Healthcare CNN Model to Detect Prostate Cancer on Multiparametric MRI”. In: *Computational Intelligence and Neuroscience* 2022 (May 2022). Ed. by Vijay KUMAR, pp. 1–11. DOI: 10.1155/2022/5497120 (cit. on p. 26).

STABILE, Armando et al. “Multiparametric MRI for prostate cancer diagnosis: current status and future directions”. In: *Nature Reviews Urology* 17.1 (July 2019), pp. 41–61. DOI: 10.1038/s41585-019-0212-4 (cit. on p. 13).

STEINKOHL, Fabian; PICHLER, Renate, and JUNKER, Daniel. “Short review of biparametric prostate MRI”. In: *memo - Magazine of European Medical Oncology* 11.4 (Nov. 2018), pp. 309–312. DOI: 10.1007/s12254-018-0458-1 (cit. on p. 14).

SUMATHIPALA, Yohan; LAY, Nathan, and TURKBHEY, Baris. “Prostate cancer detection from multi-institution multiparametric MRIs using deep convolutional neural networks”. In: *Journal of Medical Imaging* 5.04 (Dec. 2018), p. 1. DOI: 10.1117/1.jmi.5.4.044507 (cit. on p. 31).

SUNG, Hyuna et al. “Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries”. In: *CA: A Cancer Journal for Clinicians* 71.3 (Feb. 2021), pp. 209–249. DOI: 10.3322/caac.21660 (cit. on p. 11).

SYER, Tom J. et al. “The diagnostic accuracy of high b-value diffusion- and T2-weighted imaging for the detection of prostate cancer: a meta-analysis”. In: *Abdominal Radiology* 43.7 (Nov. 2017), pp. 1787–1797. DOI: 10.1007/s00261-017-1400-4 (cit. on p. 22).

T., Jose M. Castillo et al. “Classification of Clinically Significant Prostate Cancer on Multiparametric MRI: A Validation Study Comparing Deep Learning and Radiomics”. In: *Cancers* 14.1 (Dec. 2021), p. 12. DOI: 10.3390/cancers14010012 (cit. on p. 15).

TAN, Cher Heng et al. “Dynamic Contrast-Enhanced MRI for the Detection of Prostate Cancer: Meta-Analysis”. In: *American Journal of Roentgenology* 204.4 (Apr. 2015), W439–W448. DOI: 10.2214/ajr.14.13373 (cit. on p. 13).

THOMPSON, James et al. “The role of magnetic resonance imaging in the diagnosis and management of prostate cancer”. In: *BJU international* 112 (2013), pp. 6–20 (cit. on p. 19).

TWILT, Jasper J. et al. “Artificial Intelligence Based Algorithms for Prostate Cancer Classification and Detection on Magnetic Resonance Imaging: A Narrative Review”. In: *Diagnostics* 11.6 (May 2021), p. 959. DOI: 10.3390/diagnostics11060959 (cit. on p. 29).

VIOLA, P. and JONES, M. “Rapid object detection using a boosted cascade of simple features”. In: *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001*. Vol. 1. 2001, pp. I–I. DOI: 10.1109/CVPR.2001.990517 (cit. on p. 24).

WALMSLEY, Lee Anne. *The psychological well-being of men diagnosed with prostate cancer*. University of Kentucky, 2015 (cit. on p. 17).

WANG, Fei et al. “Clinically significant prostate cancer (csPCa) detection with various prostate sampling schemes based on different csPCa definitions”. In: *BMC Urology* 21.1 (Dec. 2021). DOI: 10.1186/s12894-021-00949-7 (cit. on p. 12).

WANG, Zhiwei et al. “Automated Detection of Clinically Significant Prostate Cancer in mp-MRI Images Based on an End-to-End Deep Neural Network”. In: *IEEE Transactions on Medical Imaging* 37.5 (May 2018), pp. 1127–1139. DOI: 10.1109/tmi.2017.2789181 (cit. on p. 31).

WU, Mark et al. “Transition zone prostate cancer: Logistic regression and machine-learning models of quantitative ADC, shape and texture features are highly accurate for diagnosis”.

In: *Journal of Magnetic Resonance Imaging* 50.3 (Jan. 2019), pp. 940–950. DOI: 10.1002/jmri.26674 (cit. on p. 30).

XU, Helen et al. “Prostate cancer detection using residual networks”. In: *International Journal of Computer Assisted Radiology and Surgery* 14.10 (Apr. 2019), pp. 1647–1650. DOI: 10.1007/s11548-019-01967-5 (cit. on pp. 19, 32).

YUSHKEVICH, Paul A. et al. “User-guided 3D active contour segmentation of anatomical structures: Significantly improved efficiency and reliability”. In: *NeuroImage* 31.3 (July 2006), pp. 1116–1128. DOI: 10.1016/j.neuroimage.2006.01.015 (cit. on pp. 20, 22, 23).